第11讲 图像生成模型（上）

神经网络与深度学习 2026

信息科学技术学院 吴瀚霖

hlwu@bfsu.edu.cn

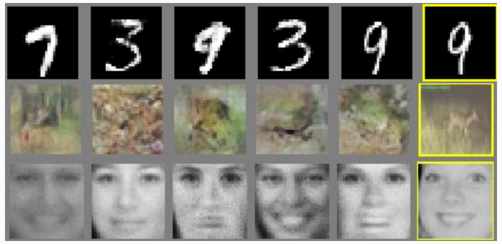

2015

2021

2022

2024

DALL·E（OpenAI）

DALL·E 2（OpenAI）

Imagen (Google)

Latent Diffusion Models （Stability AI）

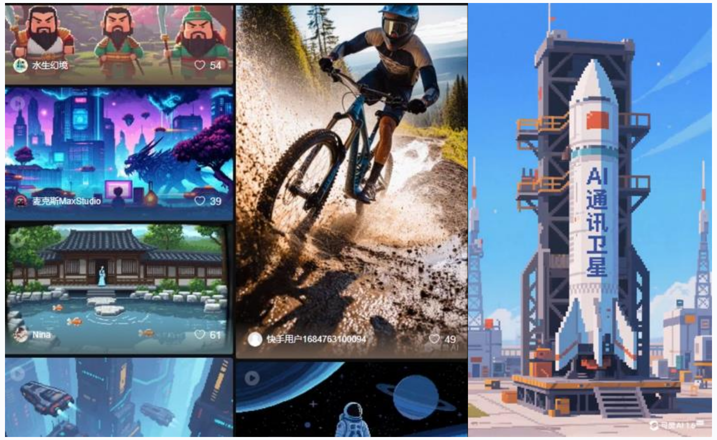

可灵 klingai.com

Sora (OpenAI)

2025
2026
1 更清晰的文字生成
(Readable Text Rendering)
未来城市
探索无限可能
FUTURE CITY
EXPLORE INFINITE POSSIBILITIES
TRAVEL
ICELAND
今日行程
10:30
产品设计评审
Product Design Review
PURE
NATURE
ORGANIC
GREEN TEA
净含量 500ml
SUNNY
BAKERY
手工曲奇
HANDMADE COOKIES
图书馆
LIBRARY
咖啡厅
CAFE
出口
EXIT
海报、招牌、界面、杂志、包装等清晰可读
2 多模态统一生成
(Multimodal Generation)
图像 (Image)
视频 (Video)
0:20
音频 (Audio)
3D (3D)
"生成一个现代风格的客厅，
阳光从左侧照进来。
Generate a modern living room
with sunlight coming from the left.
图像、视频、音频、3D 统一理解与生成
GPT-4o / Gemini 2.0 等原生多模态模型
3 可控图像编辑
(Controllable Image Editing)
原图 (Before)
编辑后 (After)
指令式编辑 (Instruction-based Editing)
"把沙发改成蓝色"
"改成橙色复古风"
主体一致性编辑 (Subject-consistent Editing)
精准控制内容、风格、颜色和主体一致性
4 长视频生成
(Long Video Generation)
多镜头故事生成（保持角色与场景一致）
02:15
1080p / 30fps
长时稳定生成（分钟级以上连续视频）
高质量、连贯的长视频叙事
5 世界模型与视频理解生成
(World Models for Video)
物理一致性的动态场景生成
视角变化与相机运动控制
交互式场景生成与预测

参考这四张PPT，逐张配上voiceover，正常语速，男声。


AI
PIZZA


AI

生成模型的特点

- **一对多**（甚至无穷）的映射
- 预测结果的**维数**通常远高于输入
- 一些预测的**可能性**比其他预测更高
- 训练数据**不可能穷尽**所有的解

DALL·E 2（OpenAI）

Imagen (Google)

GAN

2014.06:

- Goodfellow, “*Generative Adversarial Nets*”.

Goodfellow

What are some recent and potentially upcoming breakthroughs in unsupervised learning?

Yann LeCun, Director of AI Research at Facebook and Professor at NYU
Written Jul 29 · Upvoted by Joaquin Quiñonero Candela, Director Applied Machine Learning at Facebook and Huang Xiao

Adversarial training is the coolest thing since sliced bread.

I’ve listed a bunch of relevant papers in a previous answer.

Expect more impressive results with this technique in the coming years.

What’s missing at the moment is a good understanding of it so we can make it work reliably. It’s very finicky. Sort of like ConvNet were in the 1990s, when I had the reputation of being the only person who could make them work (which wasn’t true).

The GAN zoo

https://github.com/hindupuravinash/the-gan-zoo

GAN

ACGAN

BGAN

CGAN

DCGAN

EBGAN

fGAN

GoGAN

⋮

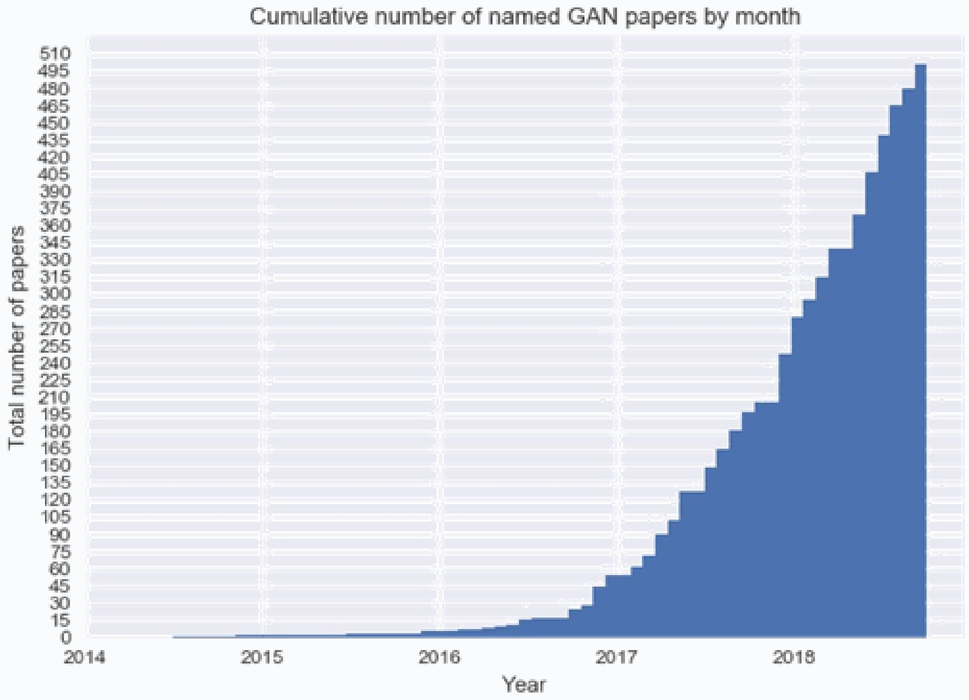

Mihaela Rosca, Balaji Lakshminarayanan, David Warde-Farley, Shakir Mohamed, “Variational Approaches for Auto-Encoding Generative Adversarial Networks”, arXiv, 2017

[2]We use the Greek α prefix for α-GAN, as AEGAN and most other Latin prefixes seem to have been taken https://deephunt.in/the-gan-zoo-79597dc8c347.

GAN的基本思想

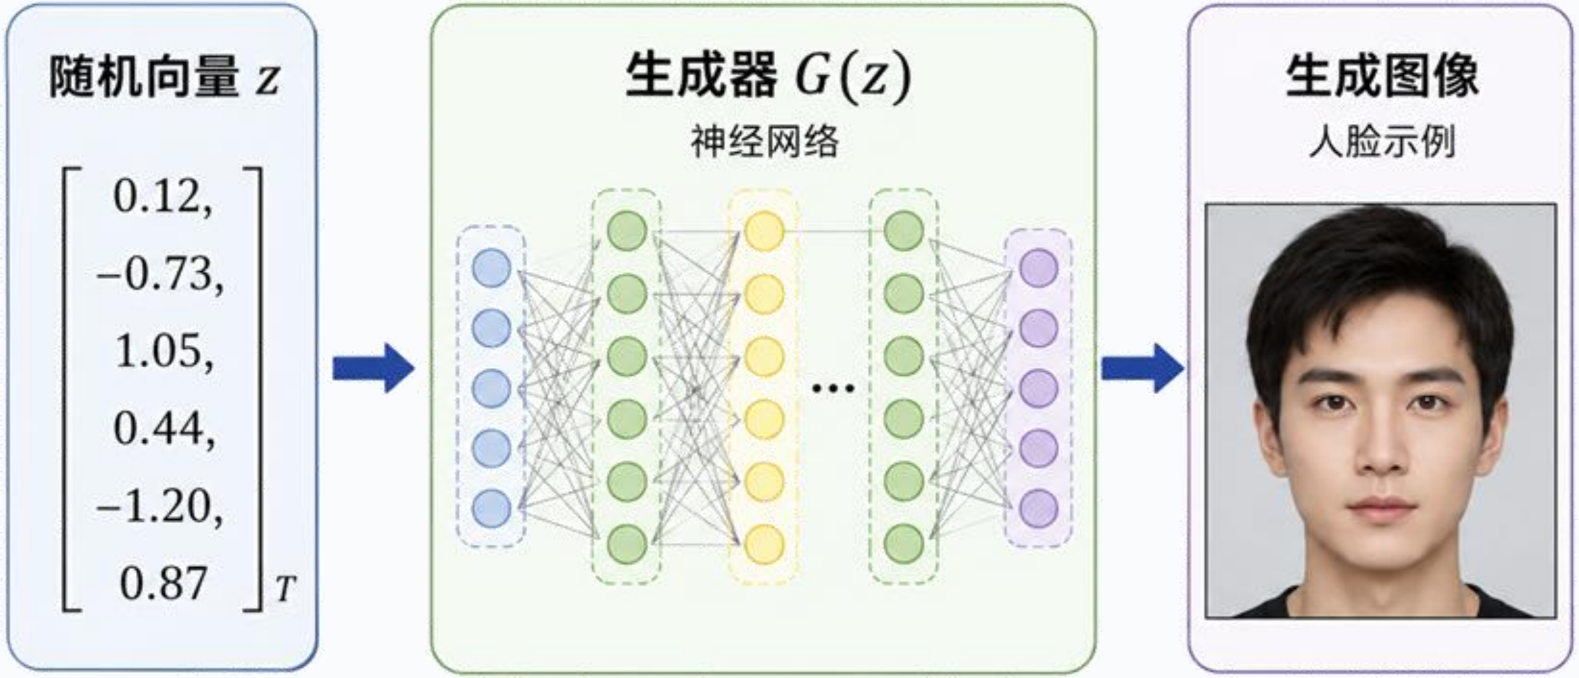

GAN的基本思想

通过调整z的不同维度，可以生成不同属性的图像

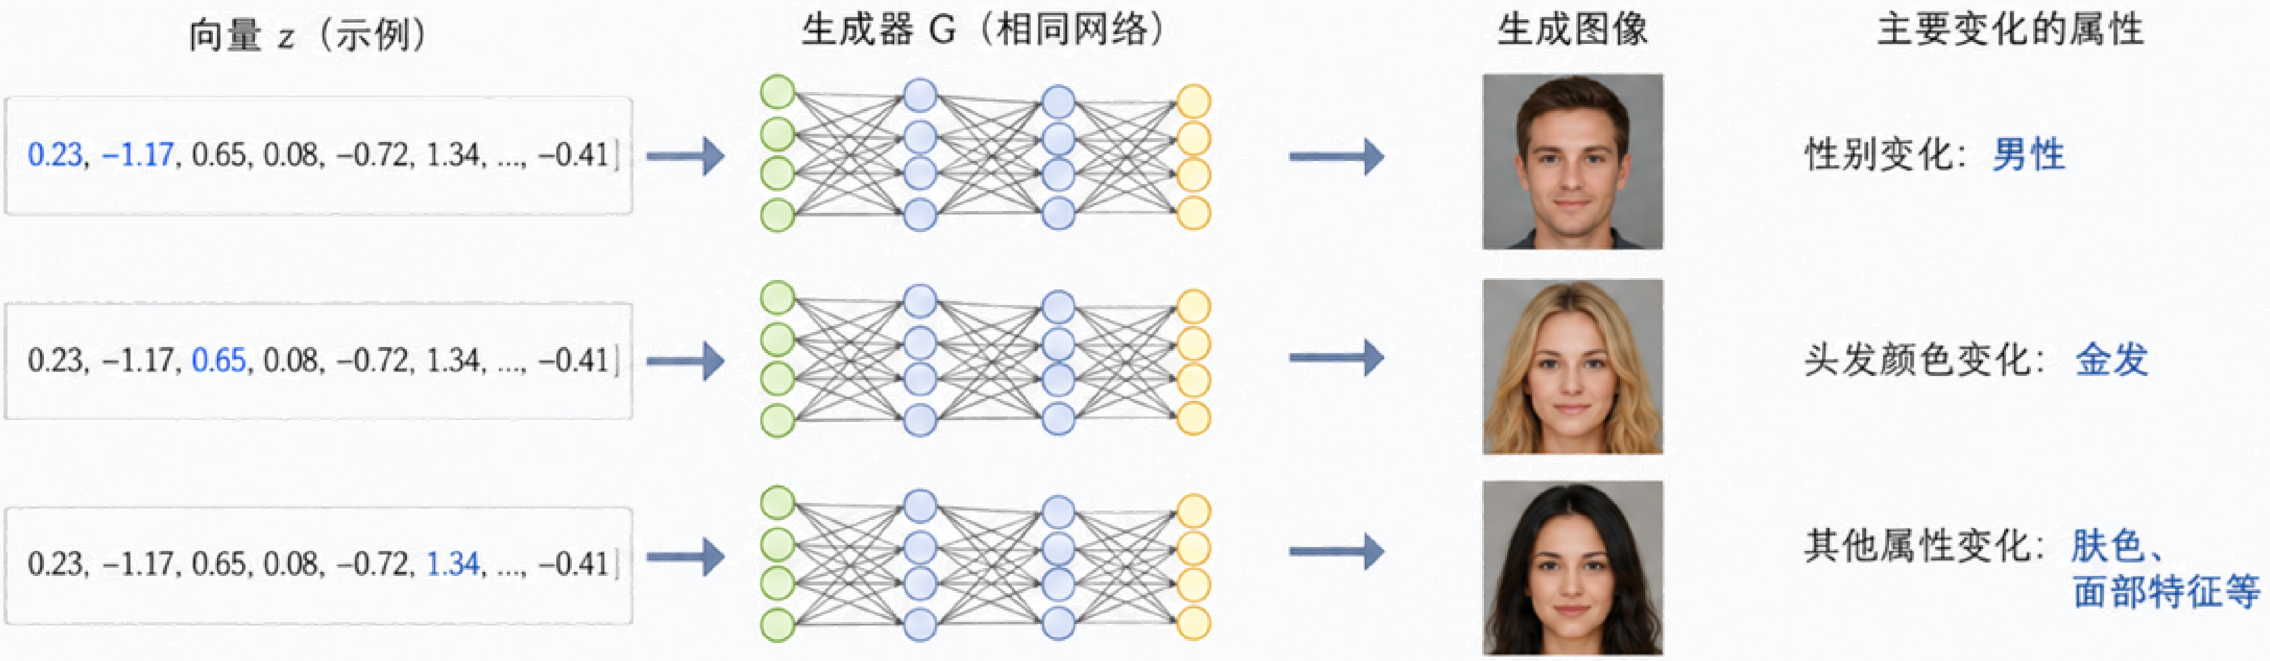

GAN的基本思想

GAN的基本思想

生成器

棕色的

枯叶蝶

蝴蝶不是棕色的

蝴蝶没有脉络

……..

判别器

GAN的基本思想

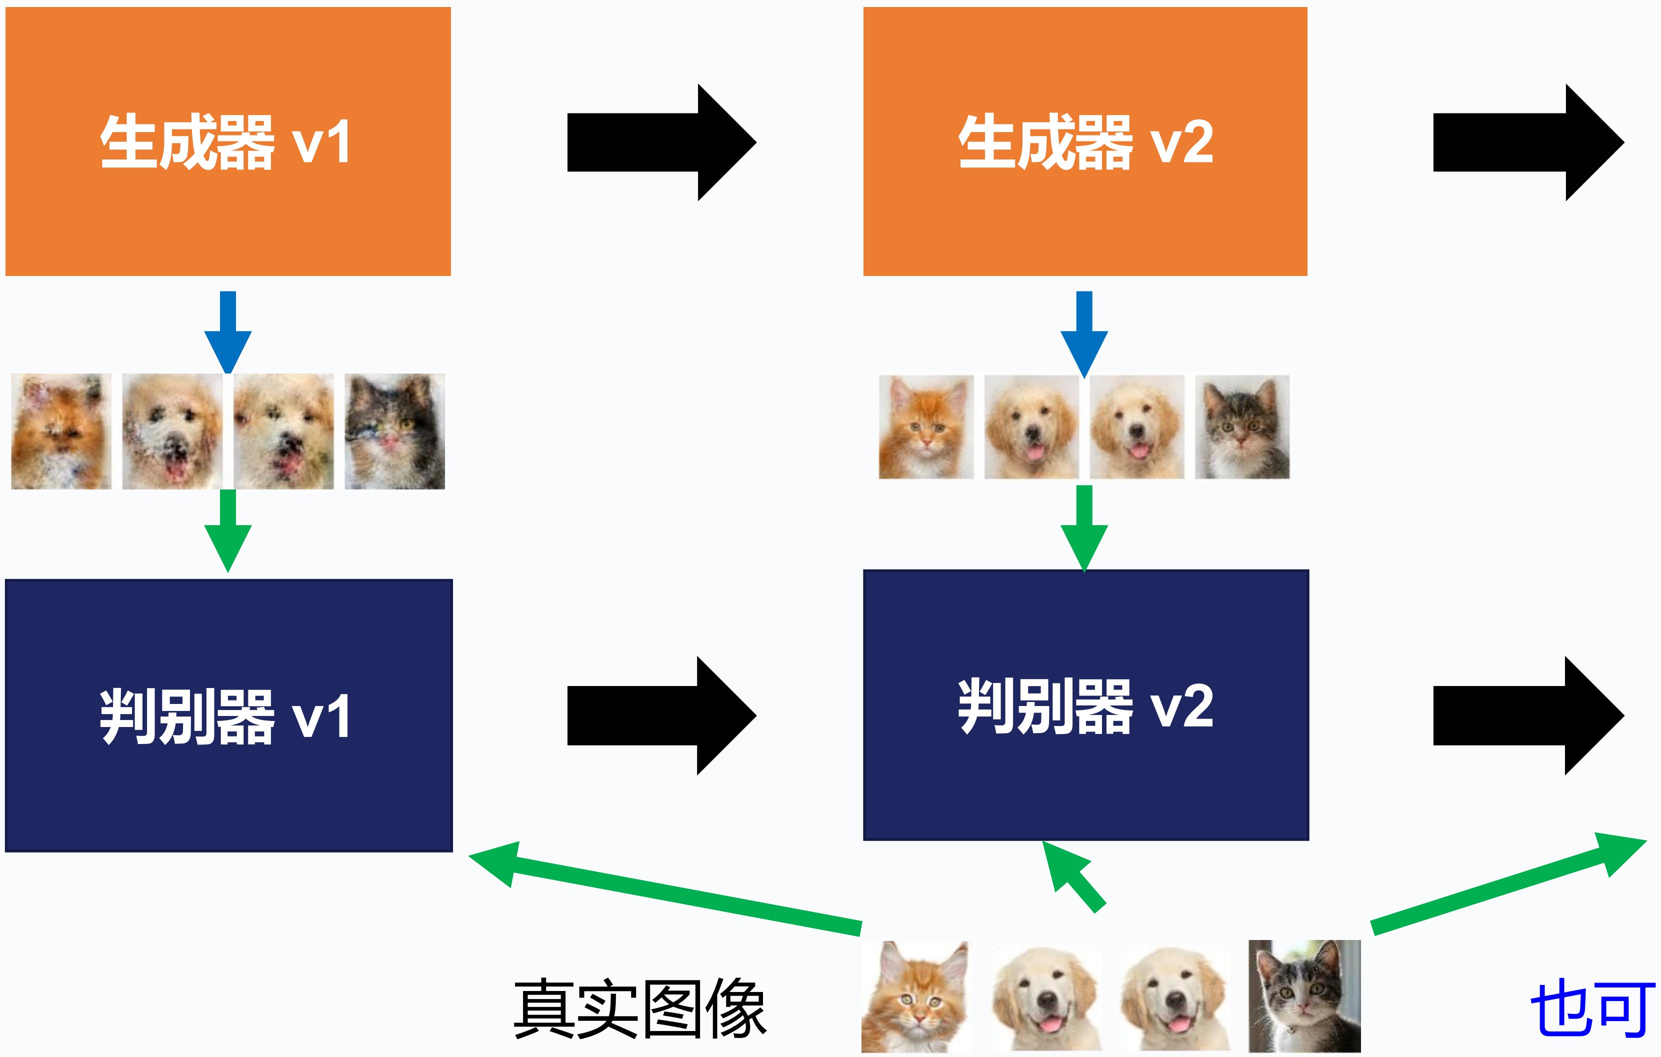

也可以从不同的角度来解释

GAN的基本思想

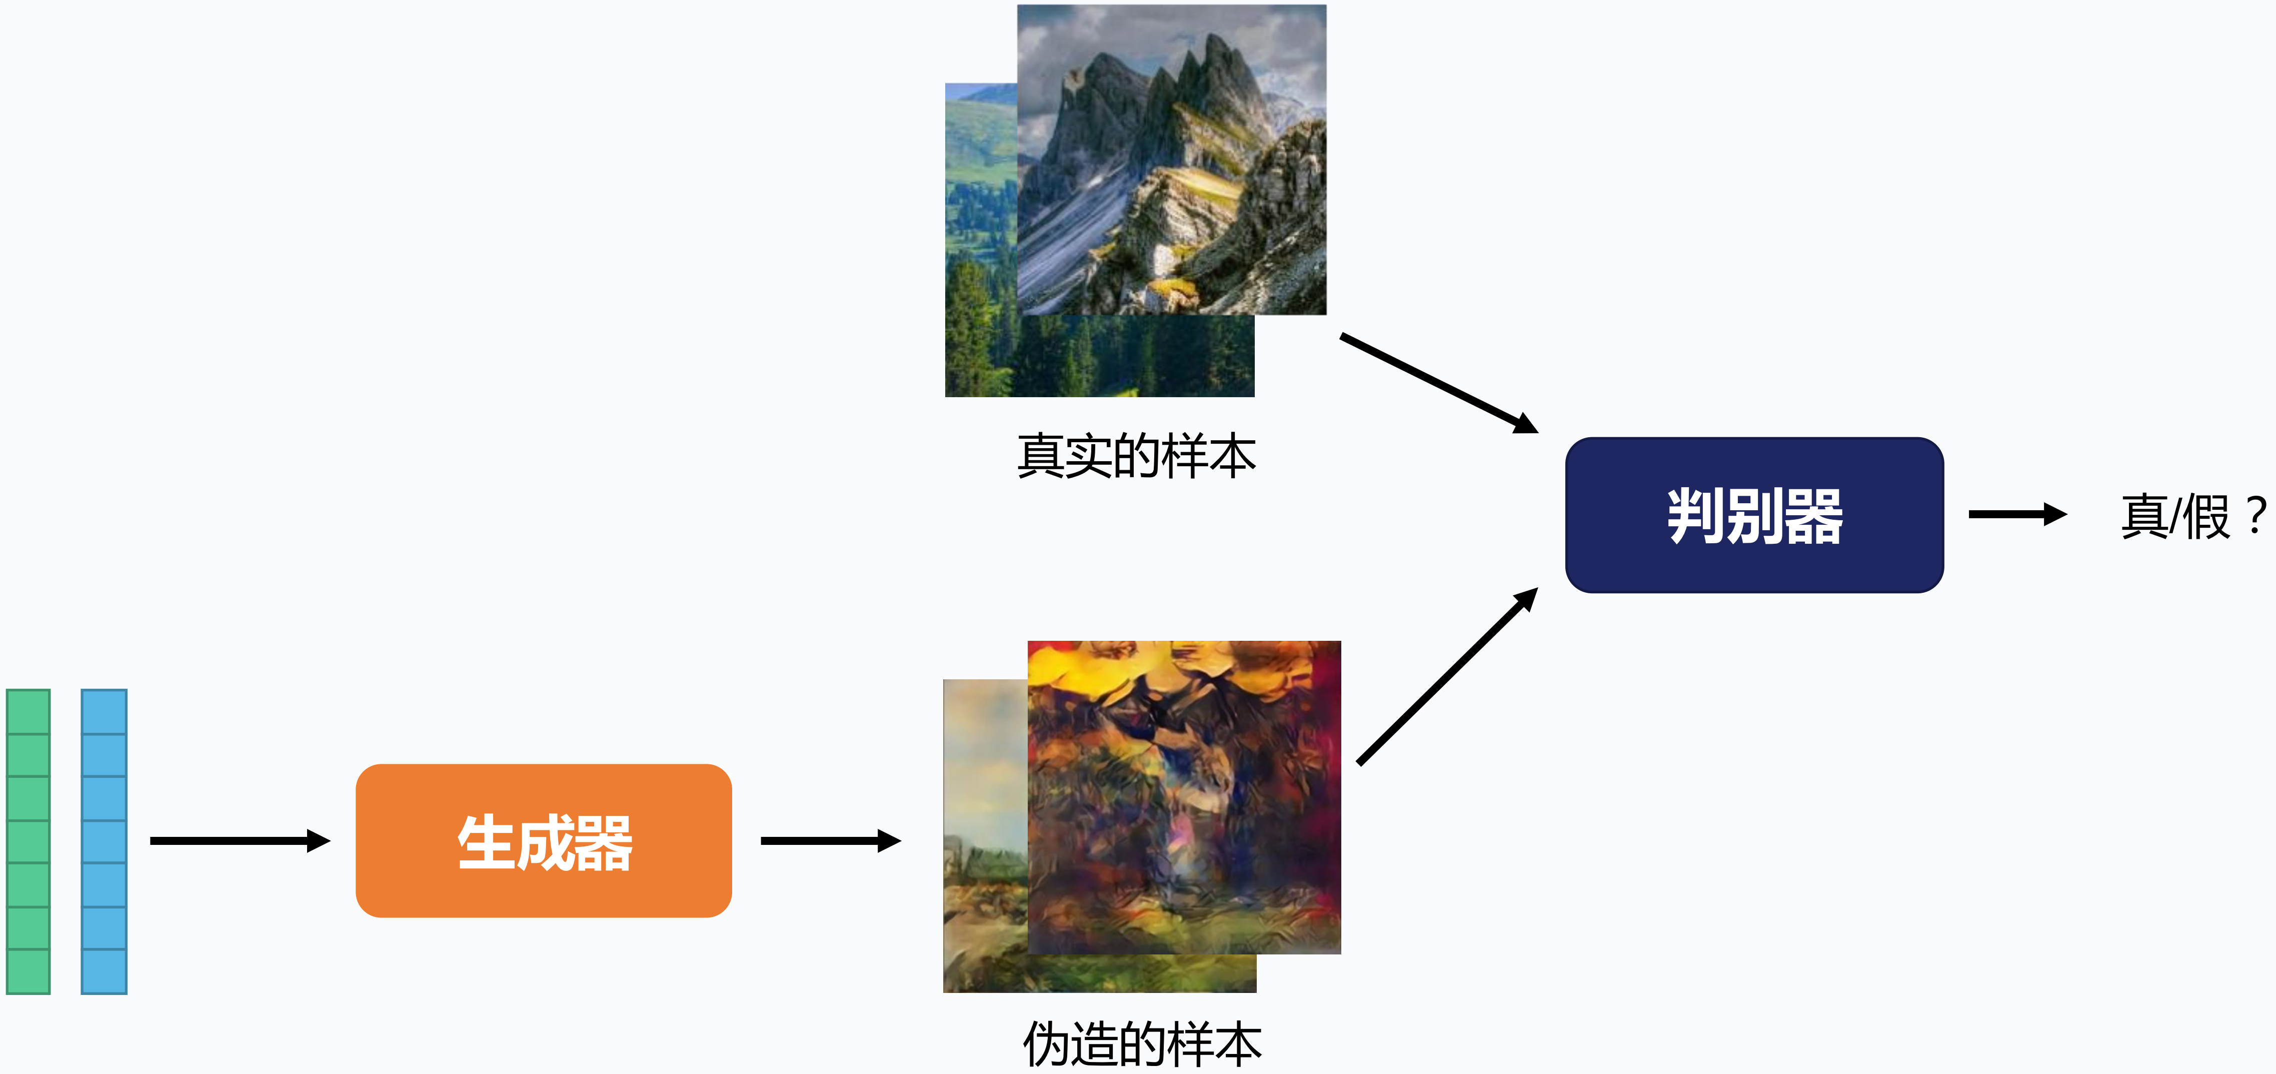

GAN的基本思想

初始化生成器与判别器 G D

在每次迭代中

- **STEP1**: 固定生成器G，更新判别器D的参数

损失函数:

$$-\mathbf{E}_{(x,y)}\left[y\log D(x)+(1-y)\log\left(1-D(x)\right)\right]$$

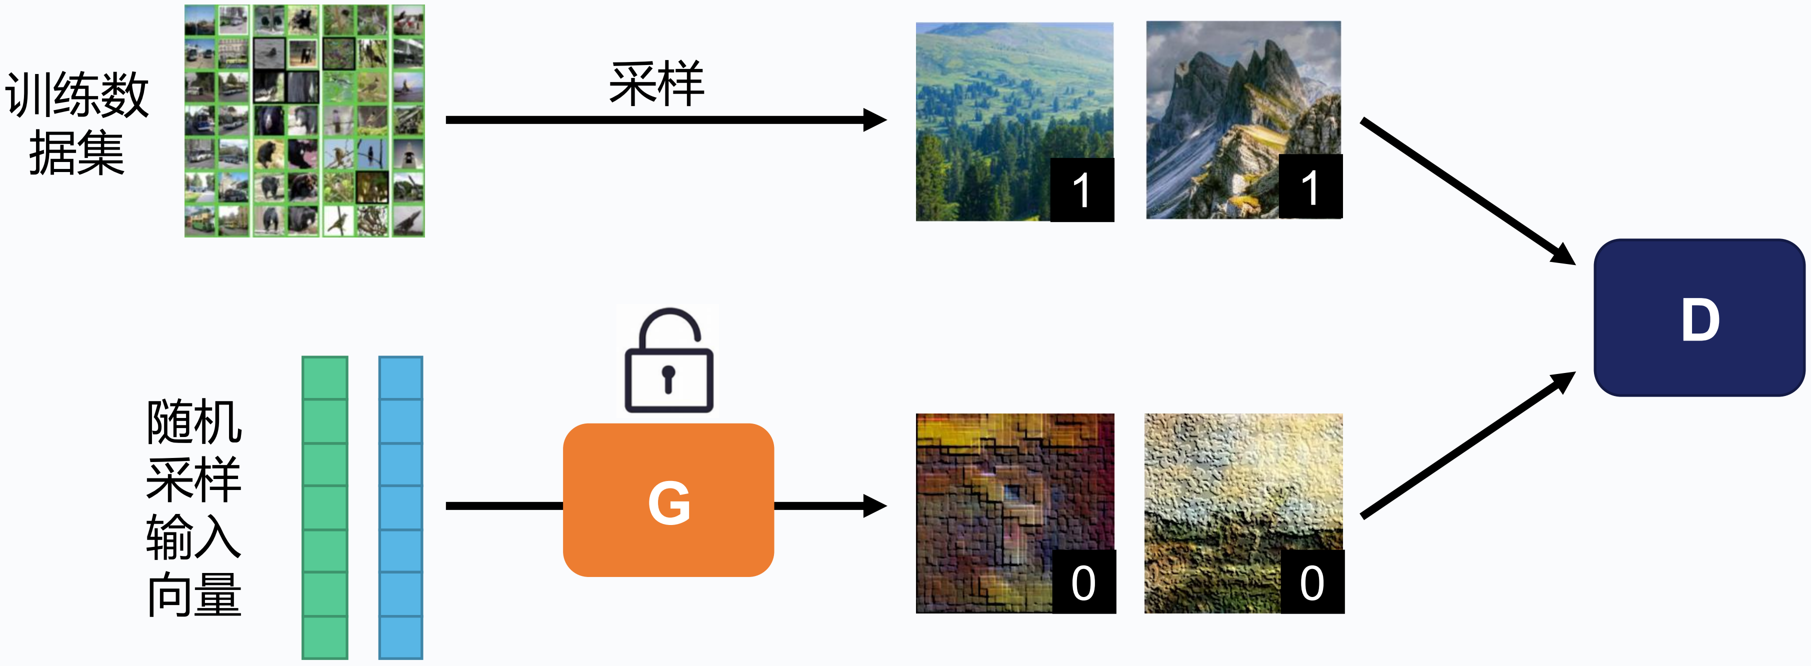

GAN的基本思想

初始化生成器与判别器 G D

在每次迭代中

- **STEP2**: 固定判别器D，更新生成器G的参数

随机采样输入向量

G

使用SGD更新生成器的参数

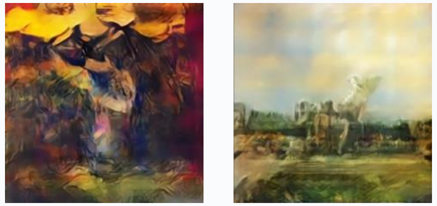

D

$D(x)$

损失函数:

$\mathbf{E}_{(x,y)}[\log(1-D(x))]$

生成模型在学什么

图像可以看作一个向量

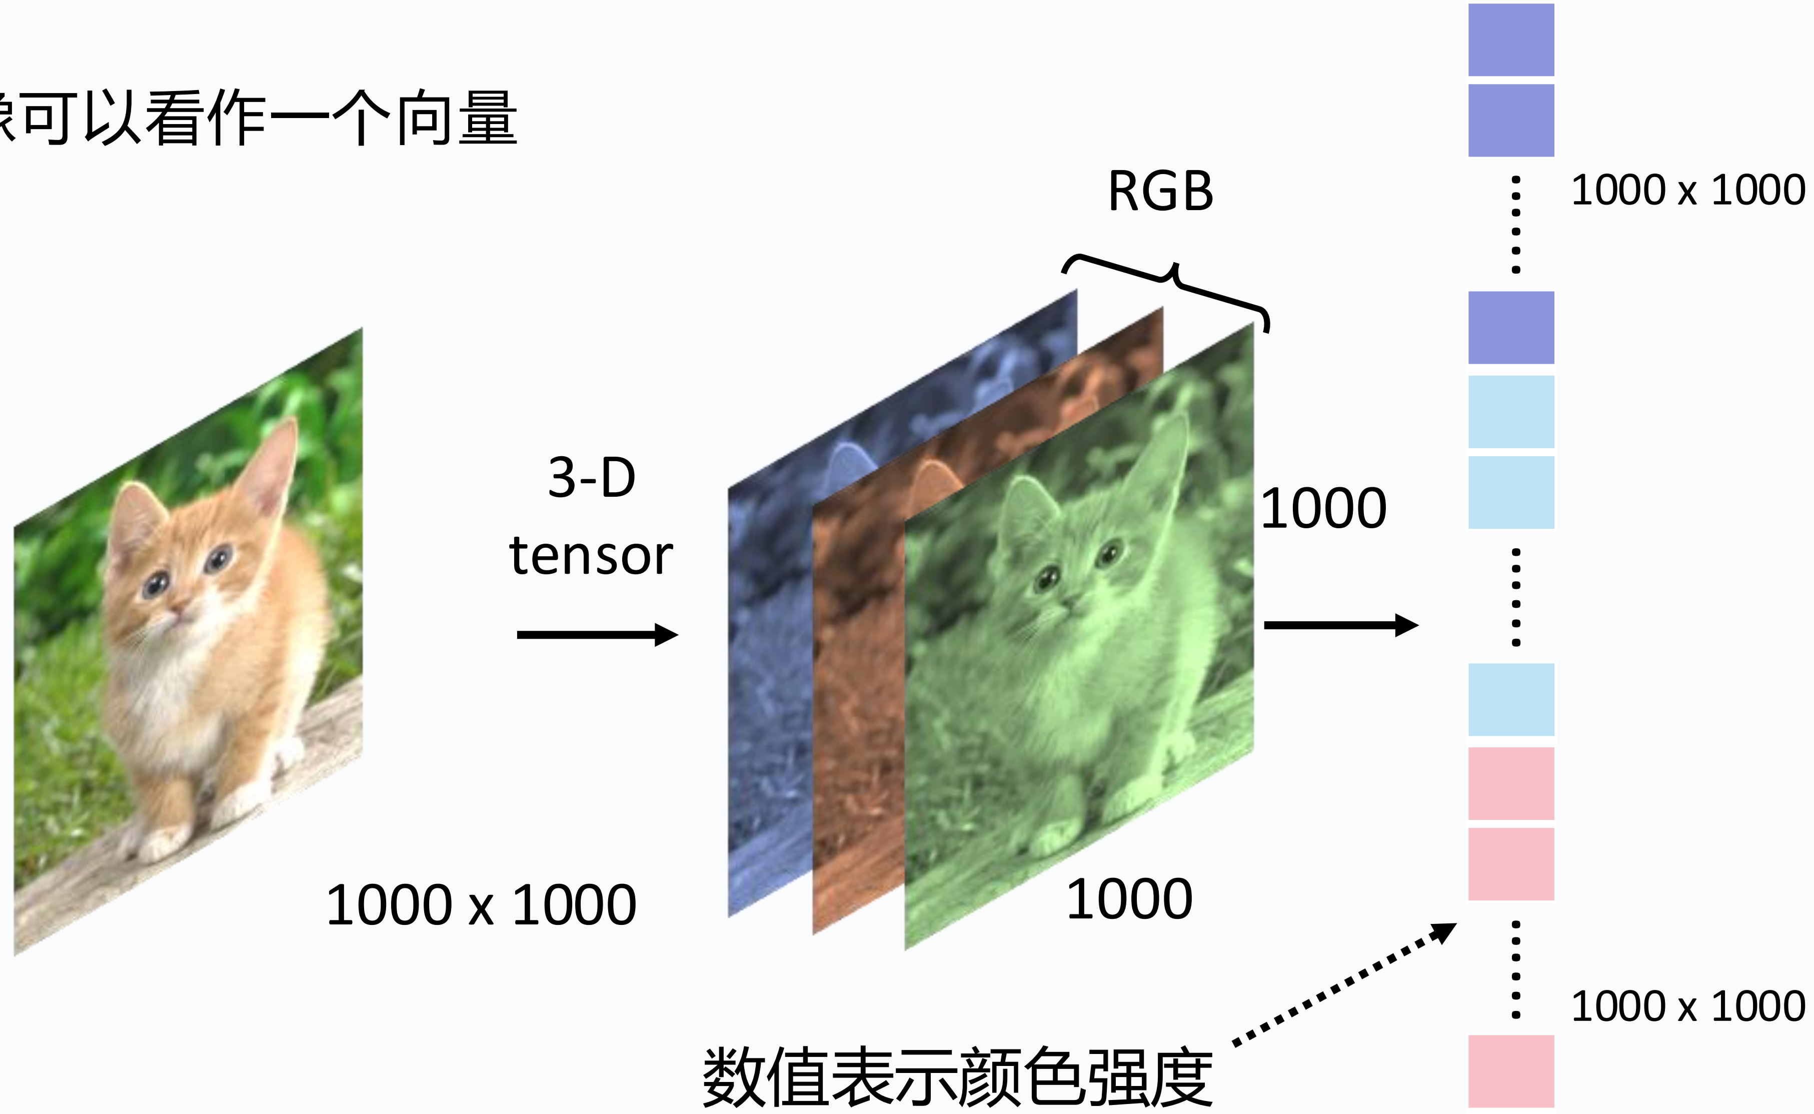

生成模型在学什么

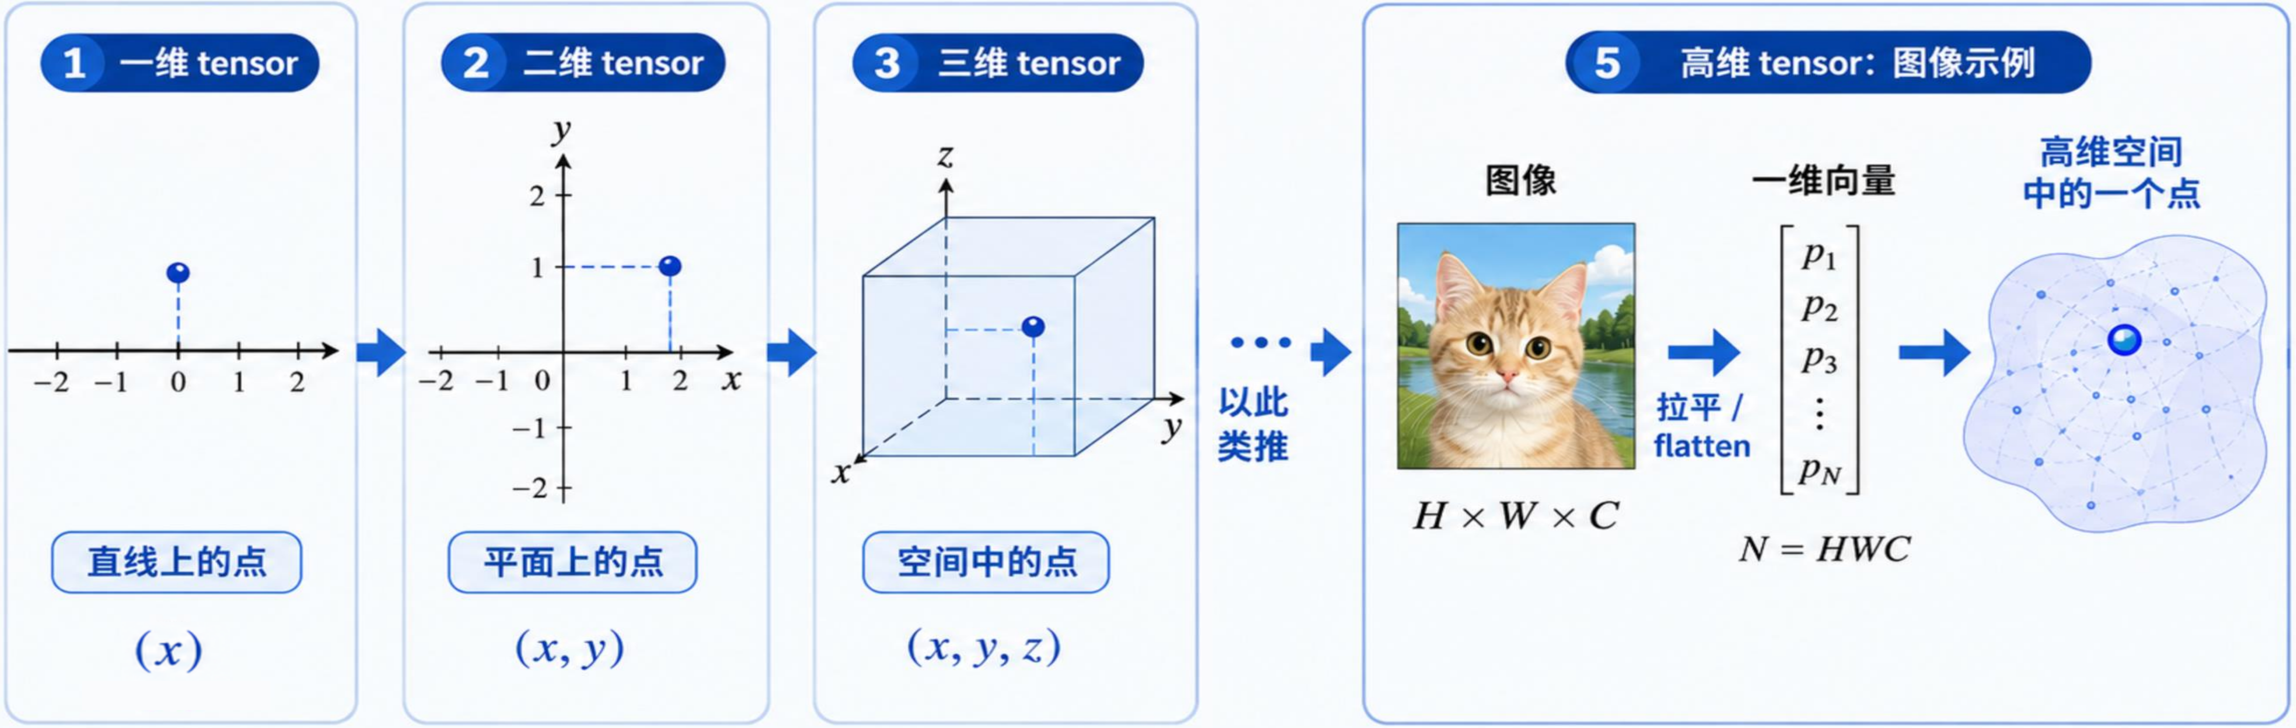

1 一维 tensor
−2 −1 0 1 2
直线上的点
(x)
2 二维 tensor
y
2
1
−2 −1 0 1 2 x
−1
−2
平面上的点
(x, y)
3 三维 tensor
z
y
x
空间中的点
(x, y, z)
以此
类推
5 高维 tensor：图像示例
图像
H × W × C
拉平 /
flatten
一维向量
p1
p2
p3
pN
N = HWC
高维空间
中的一个点

生成模型在学什么

并不是所有的点都对应自然图像

好的图像概率高，差的图像概率低

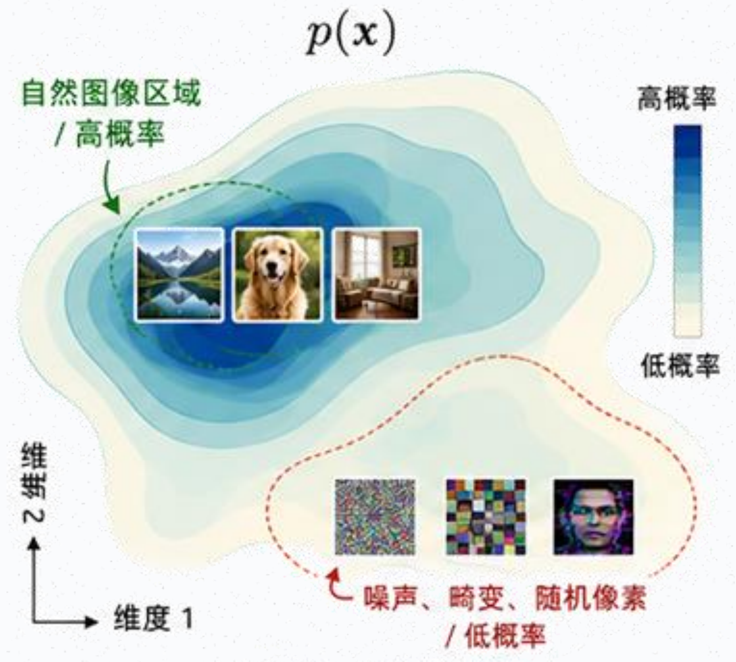

（高维空间的二维投影示意）

核心思想： 生成模型不是记住某一张图，而是在学习 “**什么样的图像更可能出现**” 。

🎯 训练 = **拟合分布**； 🎲 生成 = **从分布中采样**。

生成模型的本质是建模一个概率分布

样本

真实的分布

建模的分布

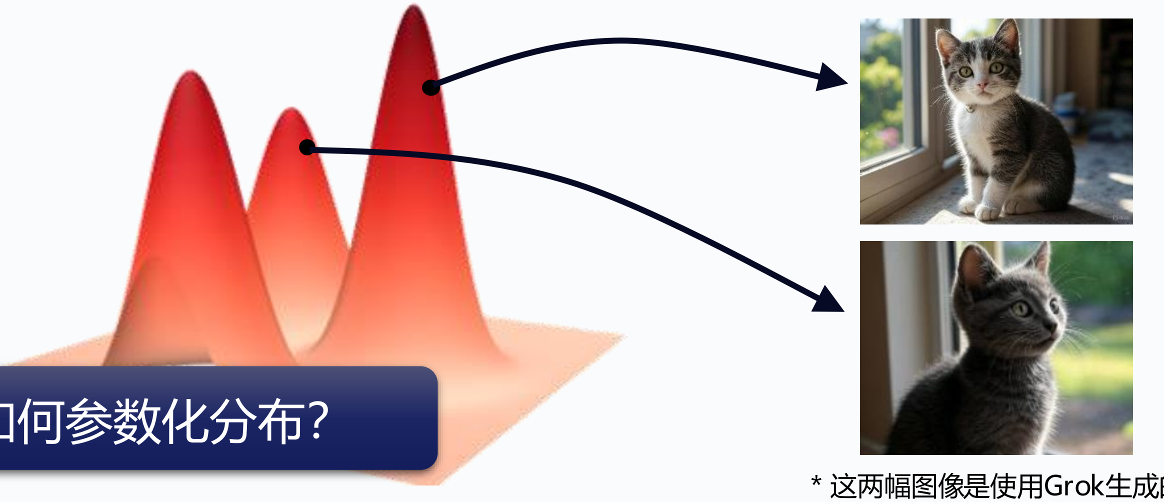

挑战1：如何参数化分布？

挑战2：如何优化分布距离？

优化目标

L(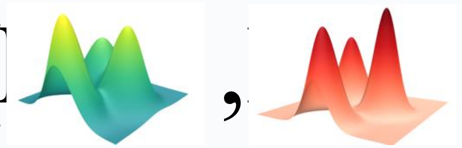)

采样

挑战3：如何高效采样？

* 这两幅图像是使用Grok生成的

如何建模概率分布?

一个映射就搞定

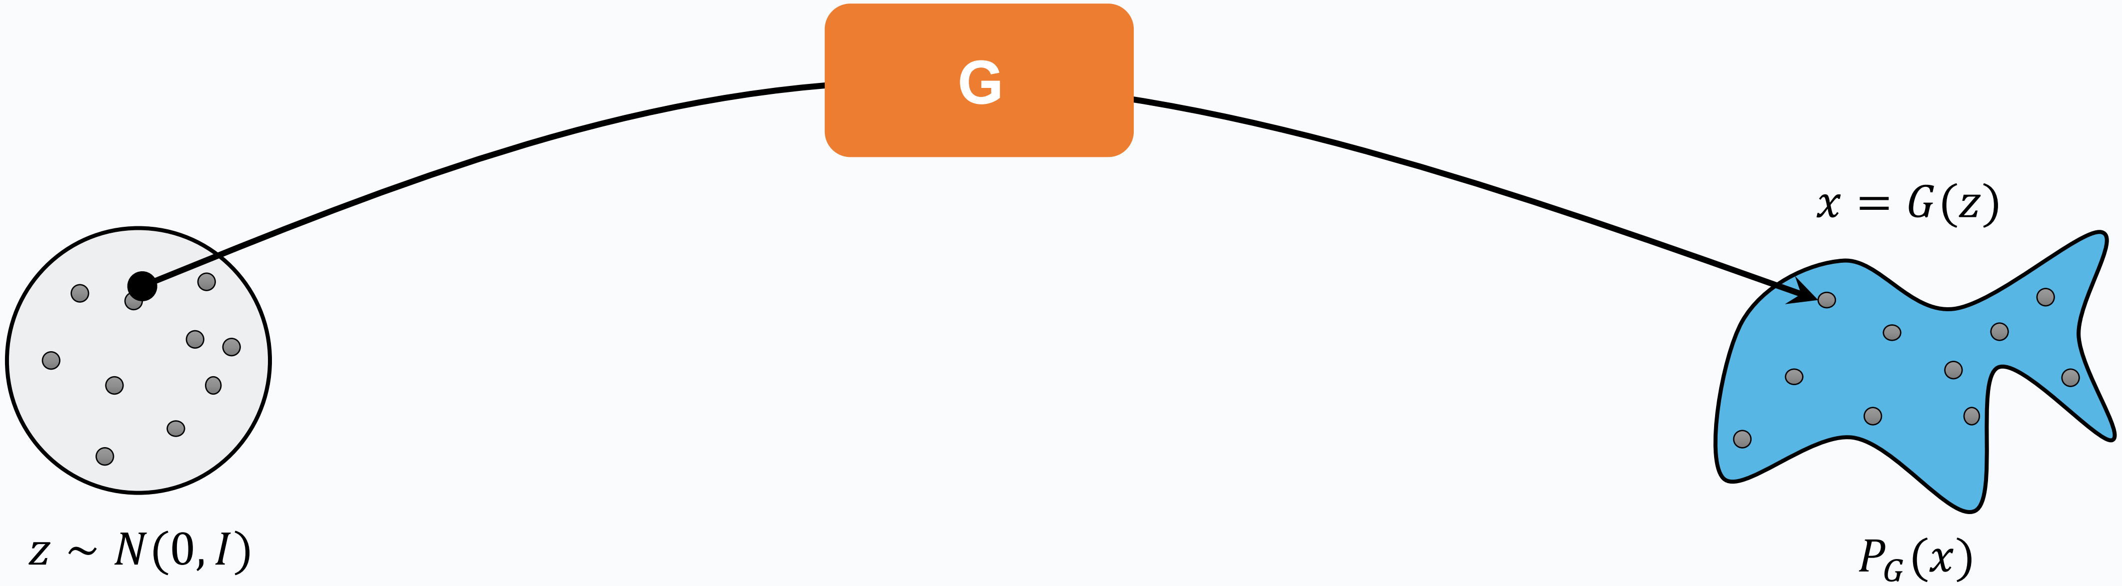

GAN的优化目标

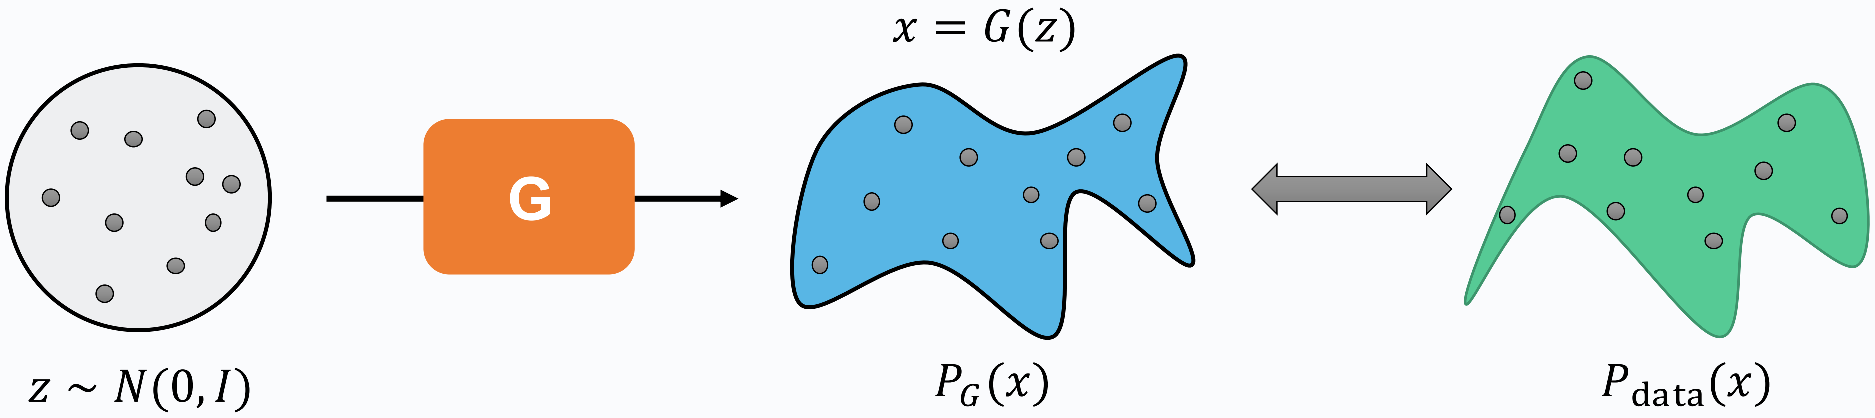

$$G^* = \arg\min \mathrm{KL}(\mathbf{P}_G || \mathbf{P}_{\text{data}})$$

某种衡量分布距离的函数

GAN的优化目标

判别器D

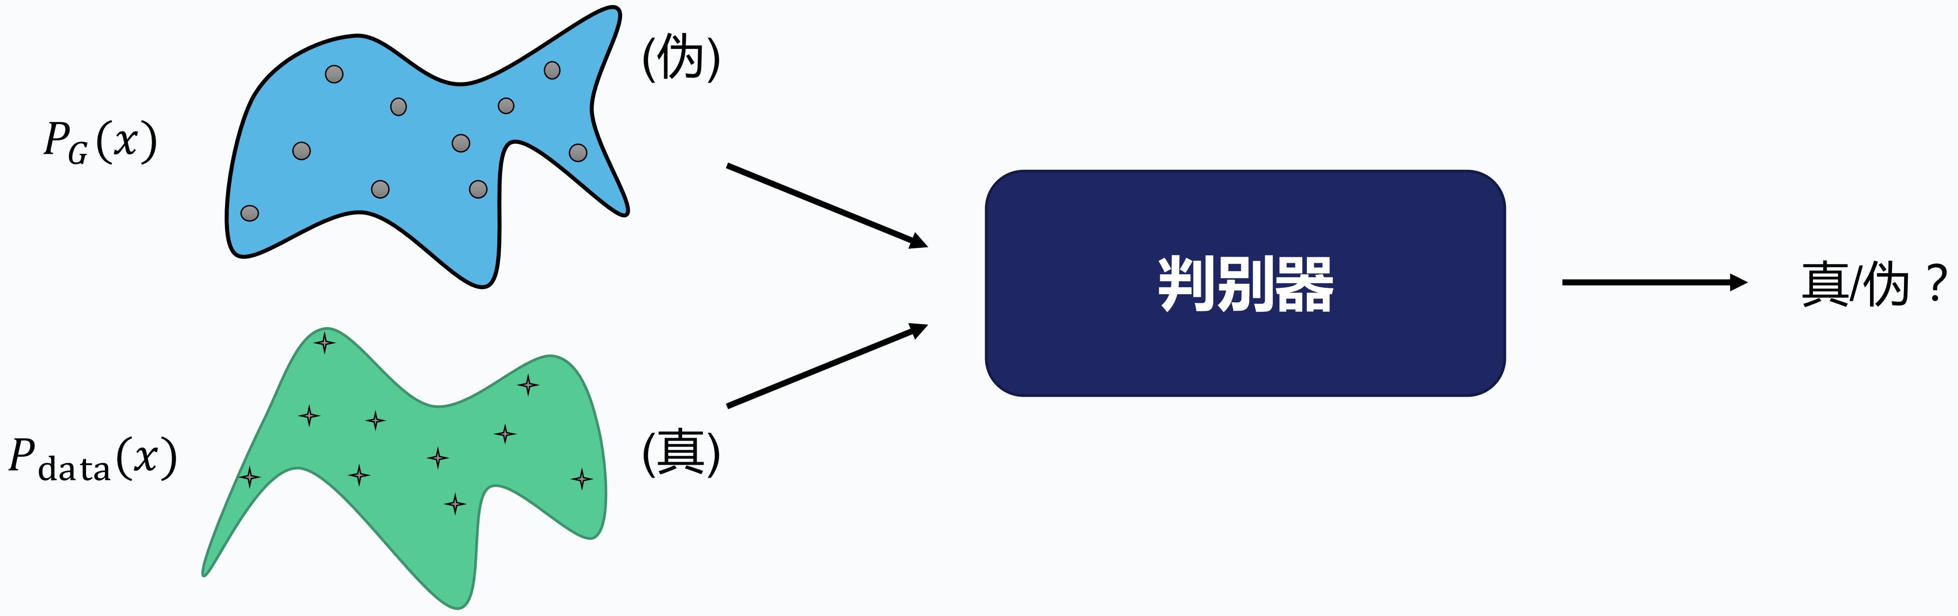

判别器的作用就是帮我们衡量分布间的距离

VAE

自编码器

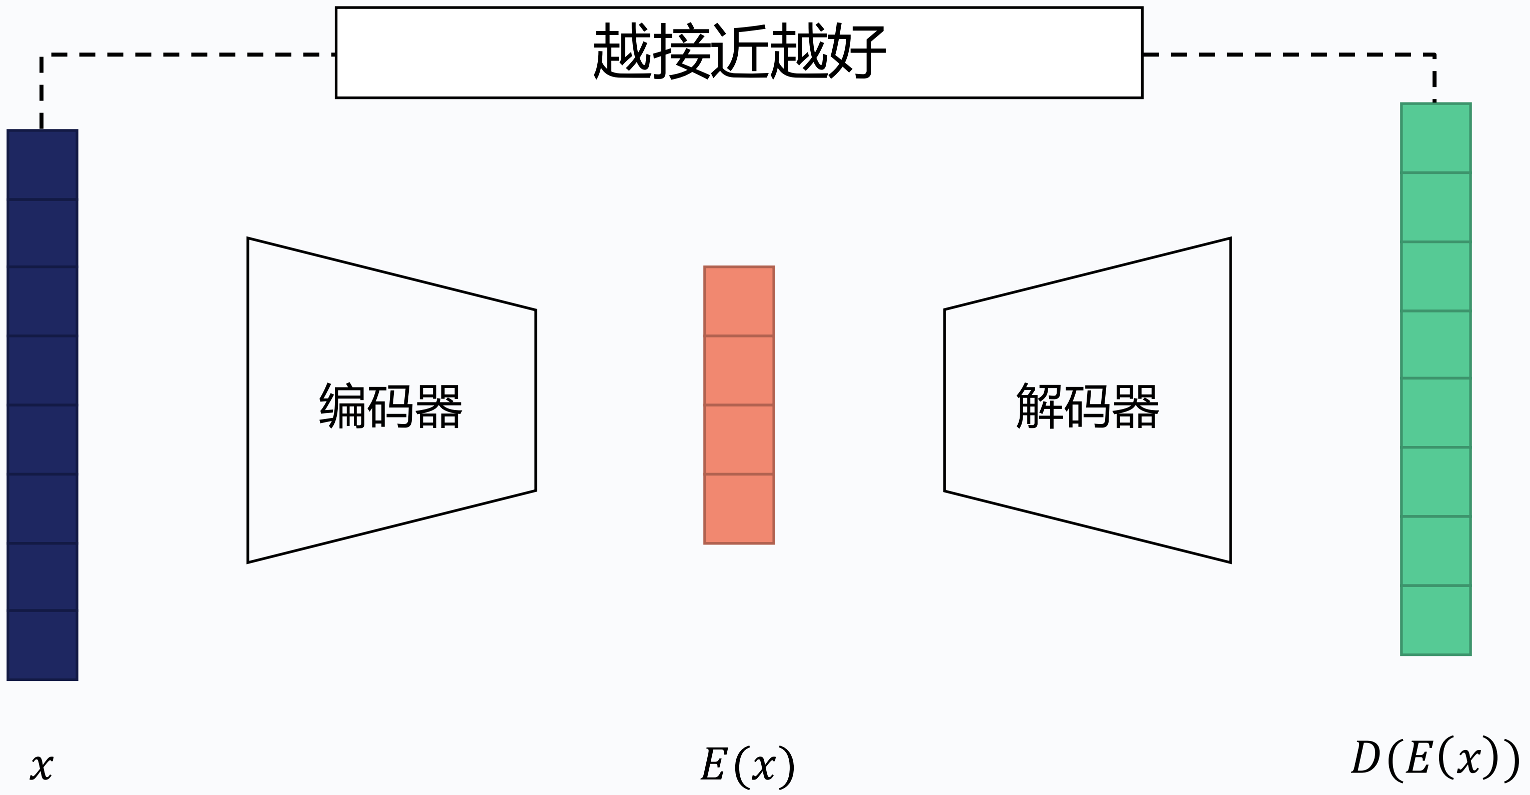

自编码器

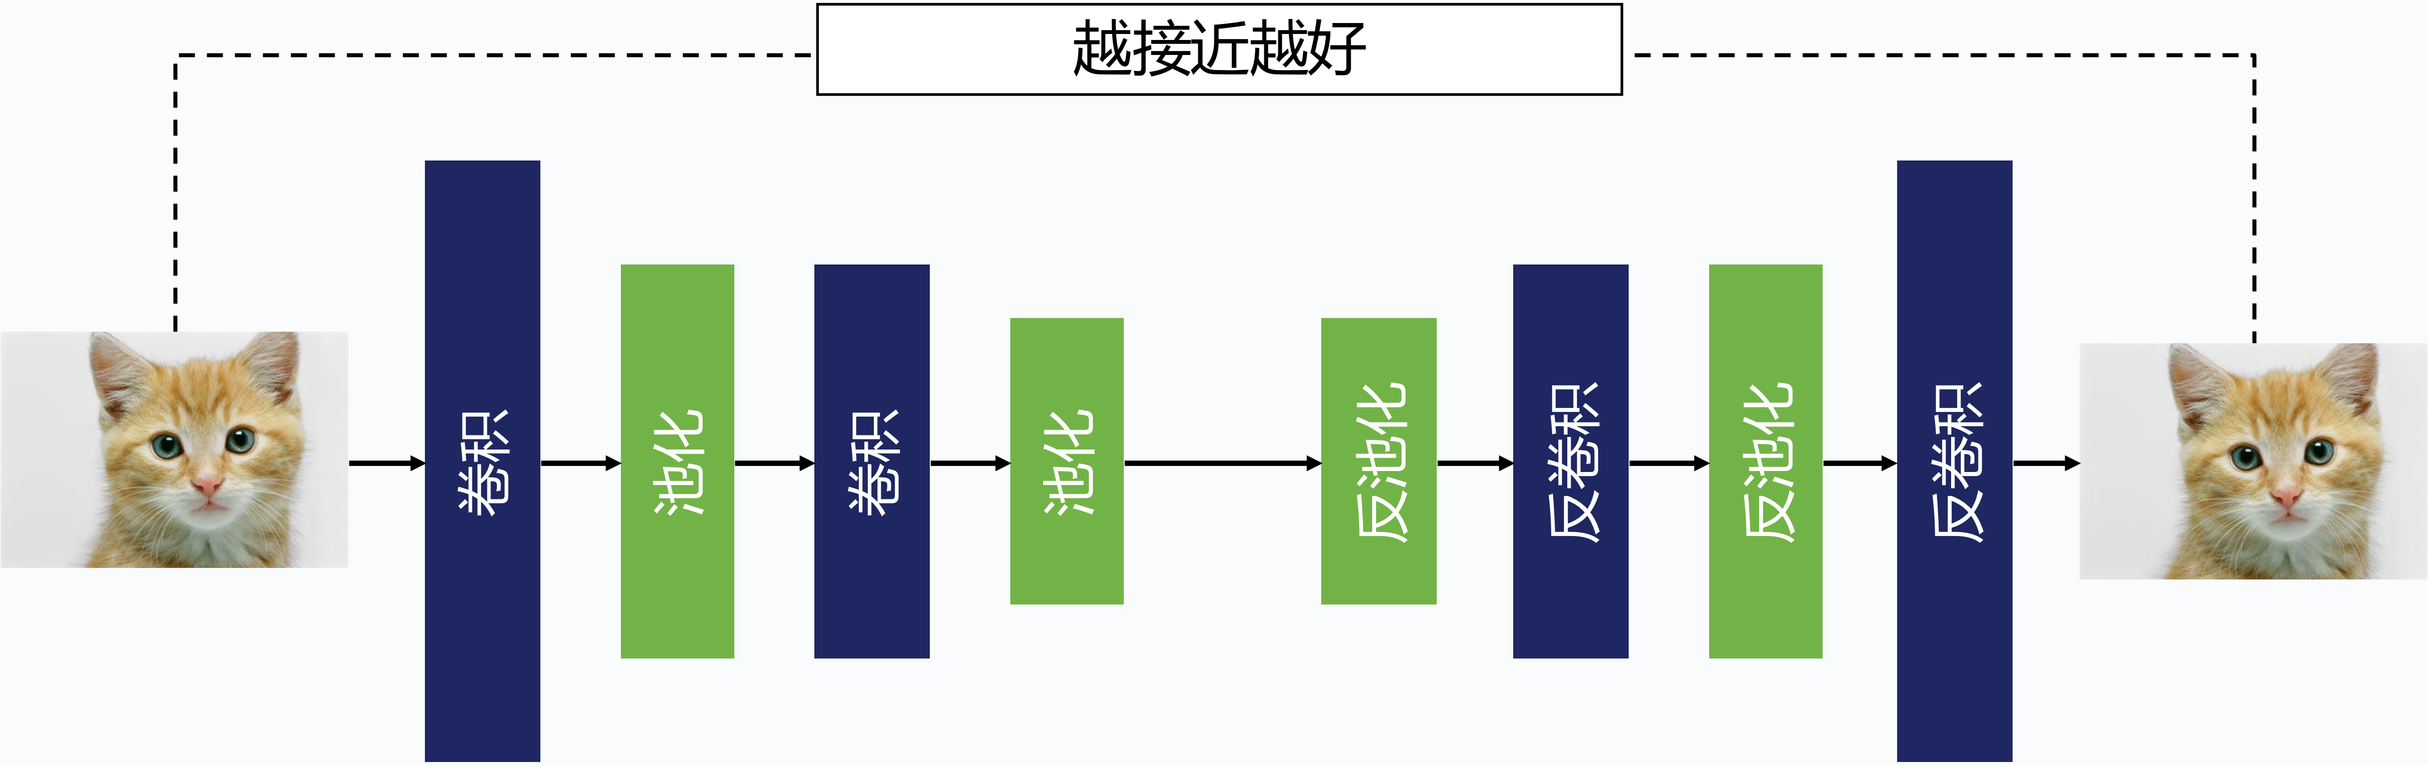

反卷积

低维特征映射到高维特征

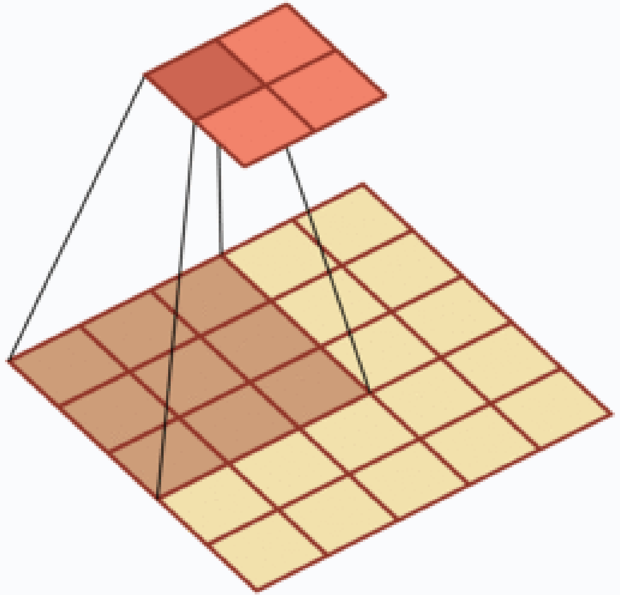

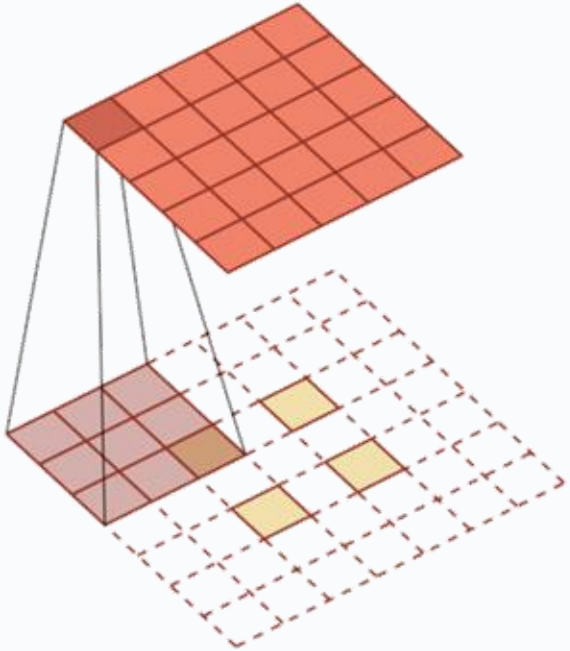

自编码器可以降维

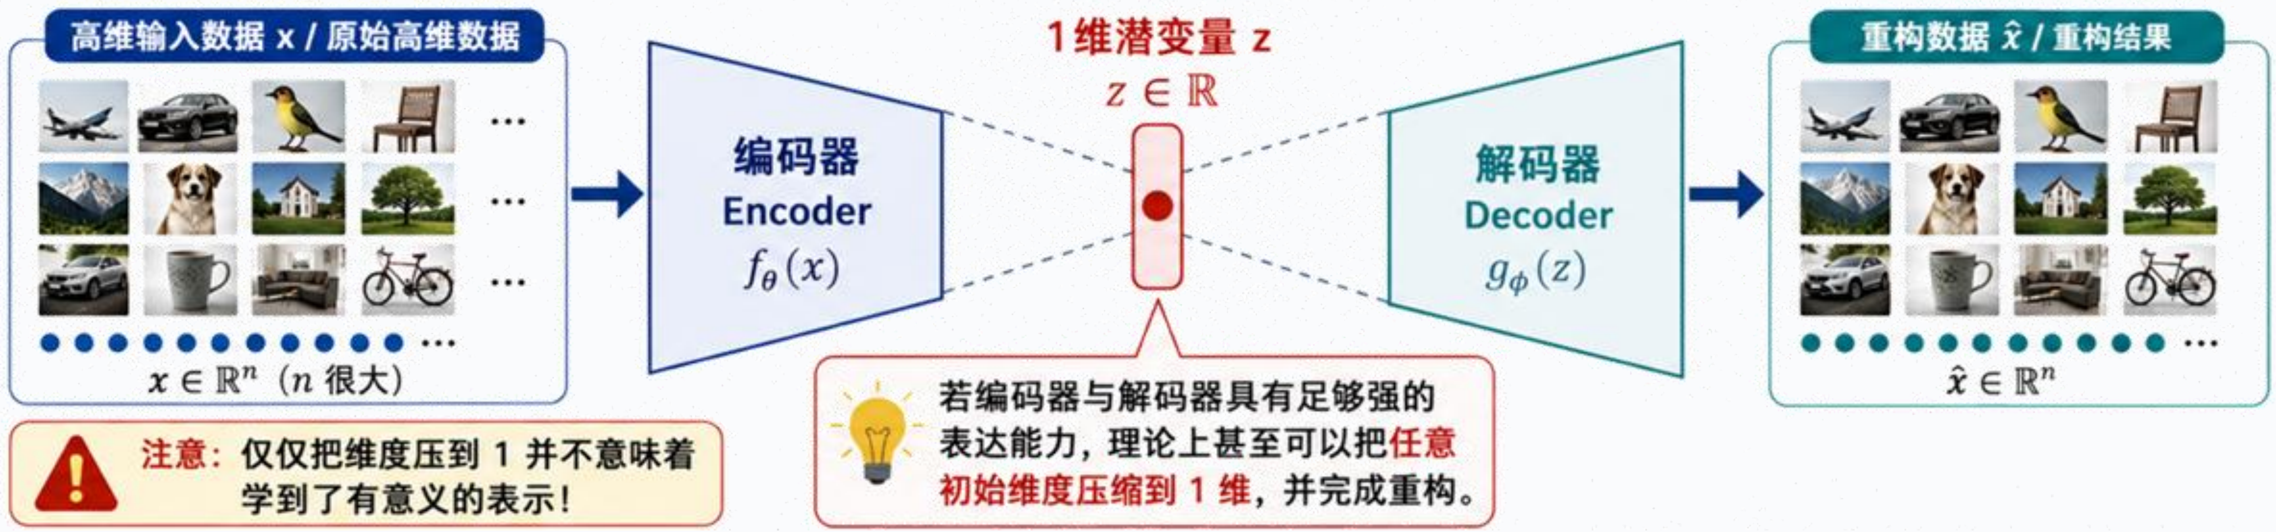

结论：降维不是目的，识别并保留数据的**主要结构**，才是核心。

什么叫保留数据的结构

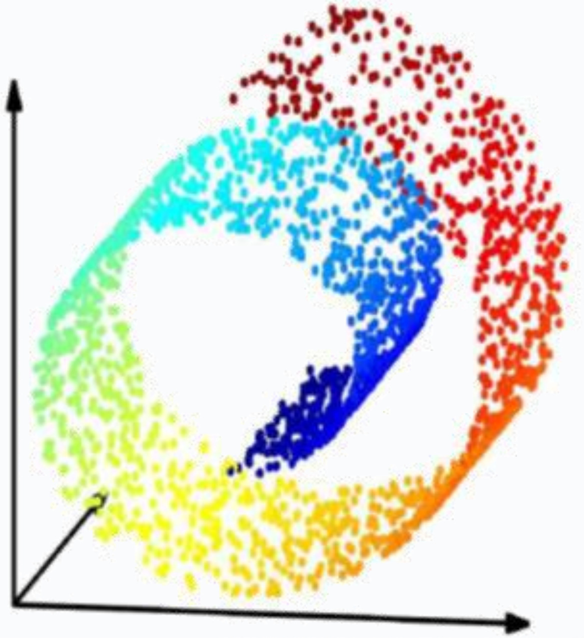

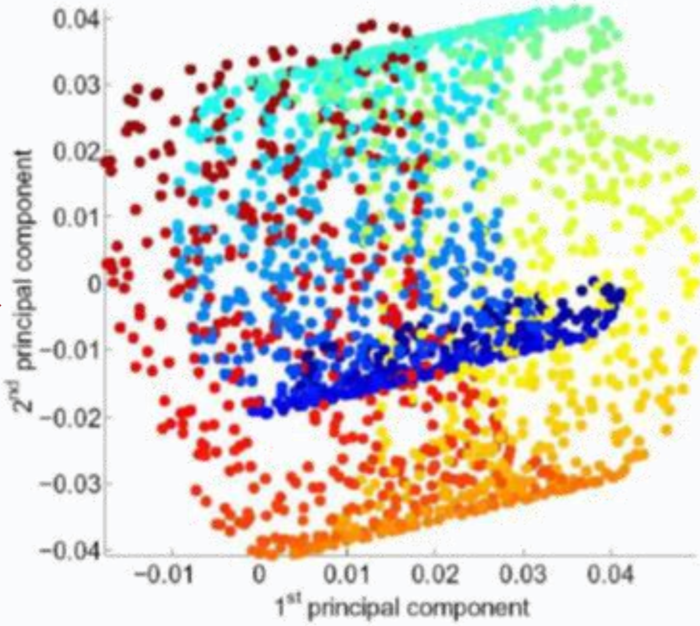
0.04
0.03
0.02
0.01
0
−0.01
−0.02
−0.03
−0.04
−0.01
0
0.01
0.02
0.03
0.04
2nd principal component
1st principal component

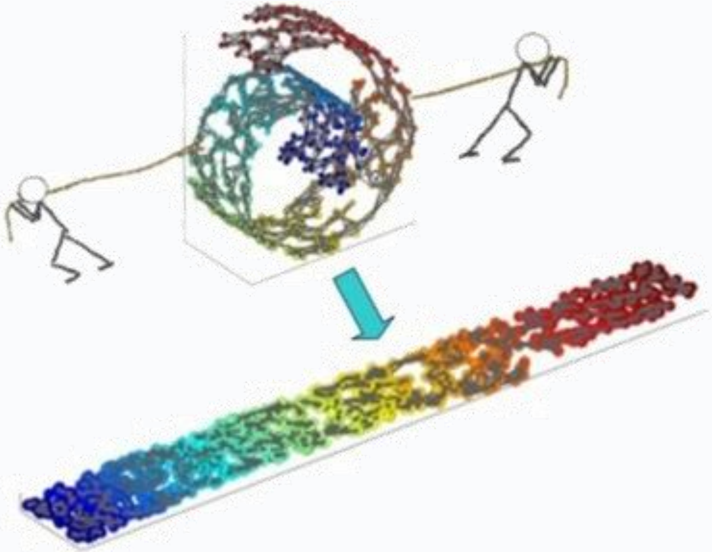

什么叫有意义的表示

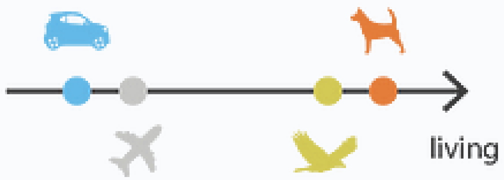

一维编码

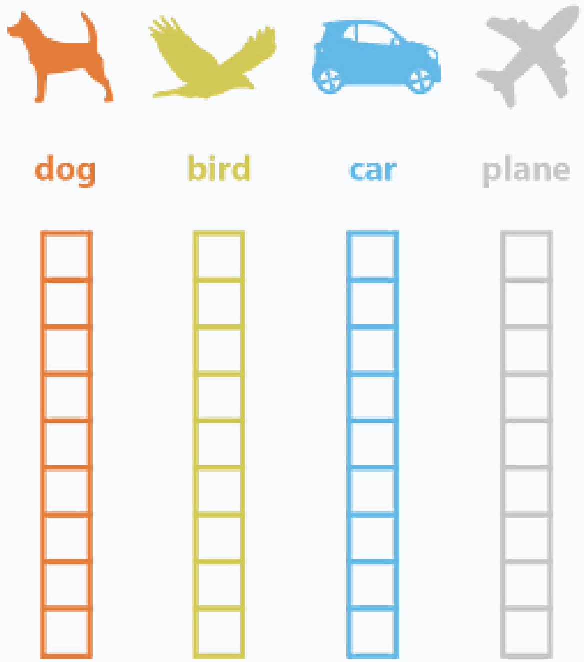

原始特征

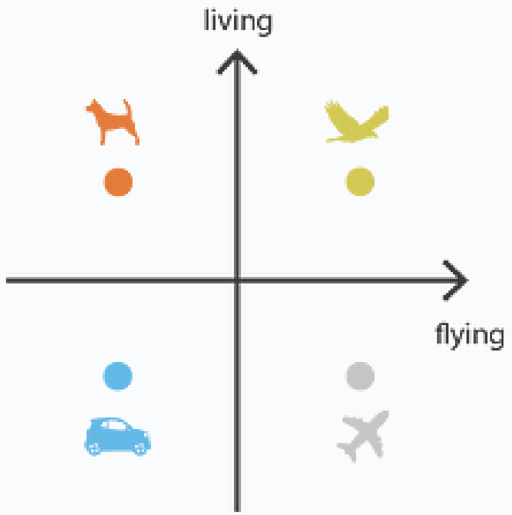

二维编码

自编码器作为生成模型

解码器看起来能生成图像

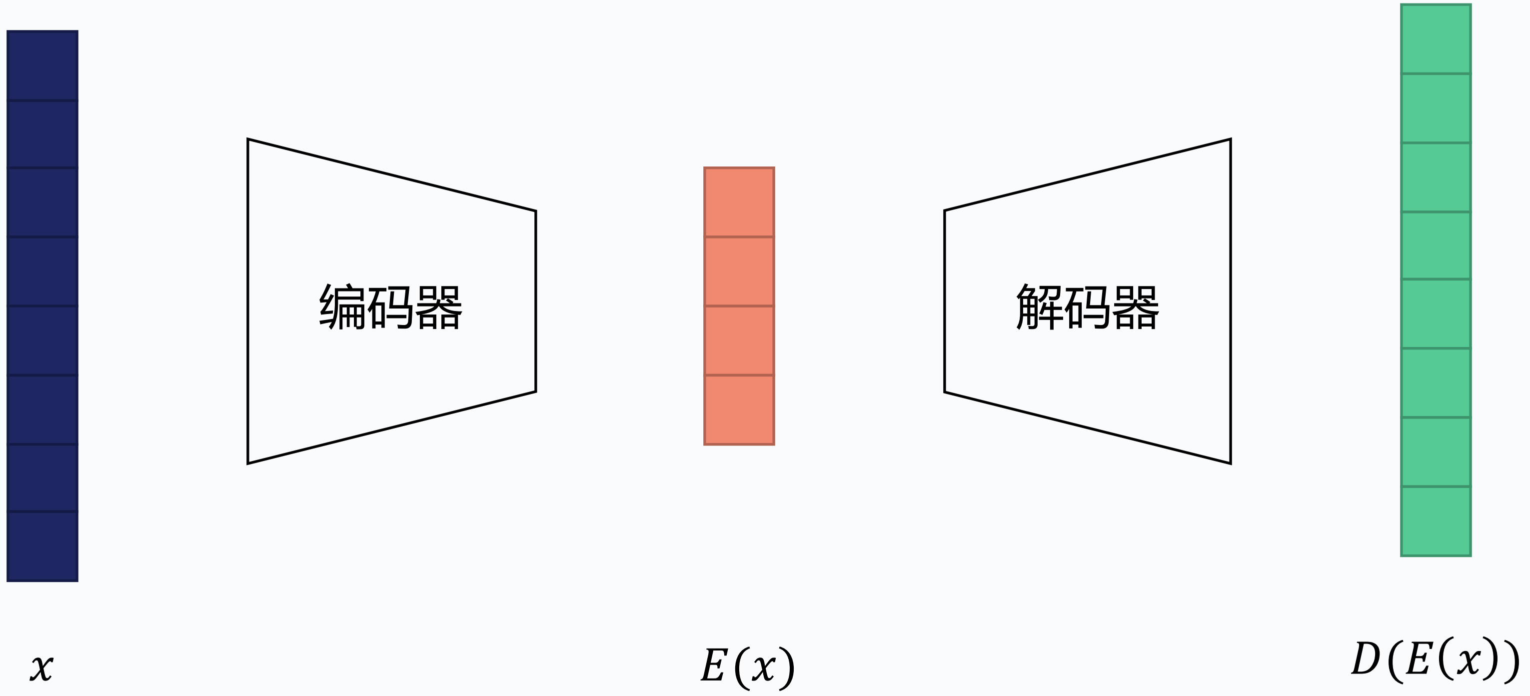

自编码器作为生成模型

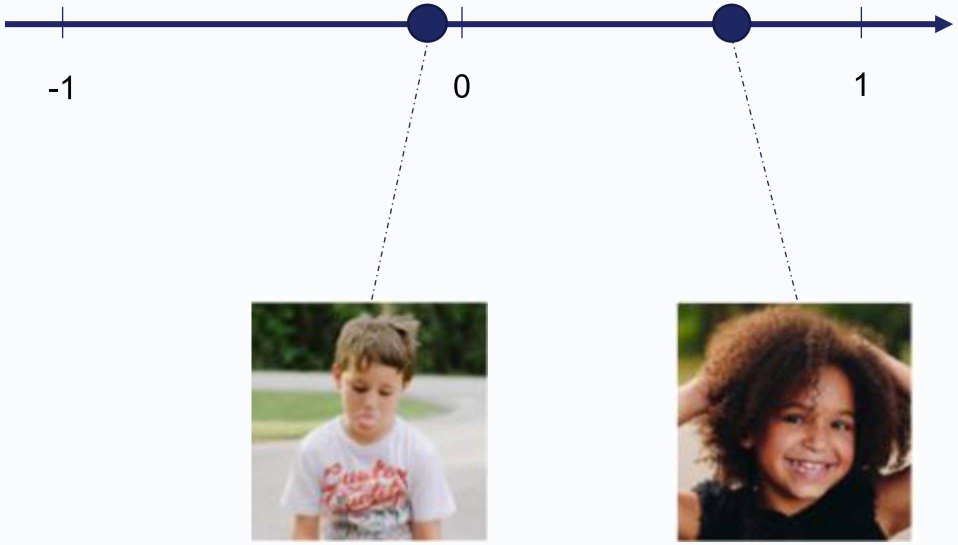

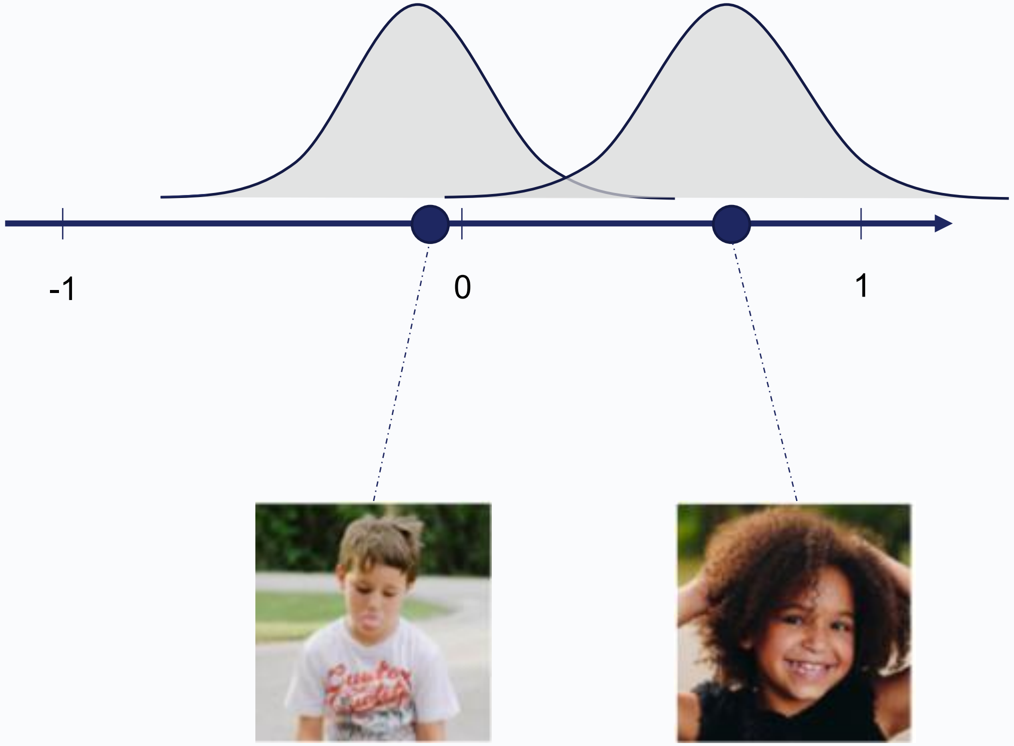

原始的自编码器

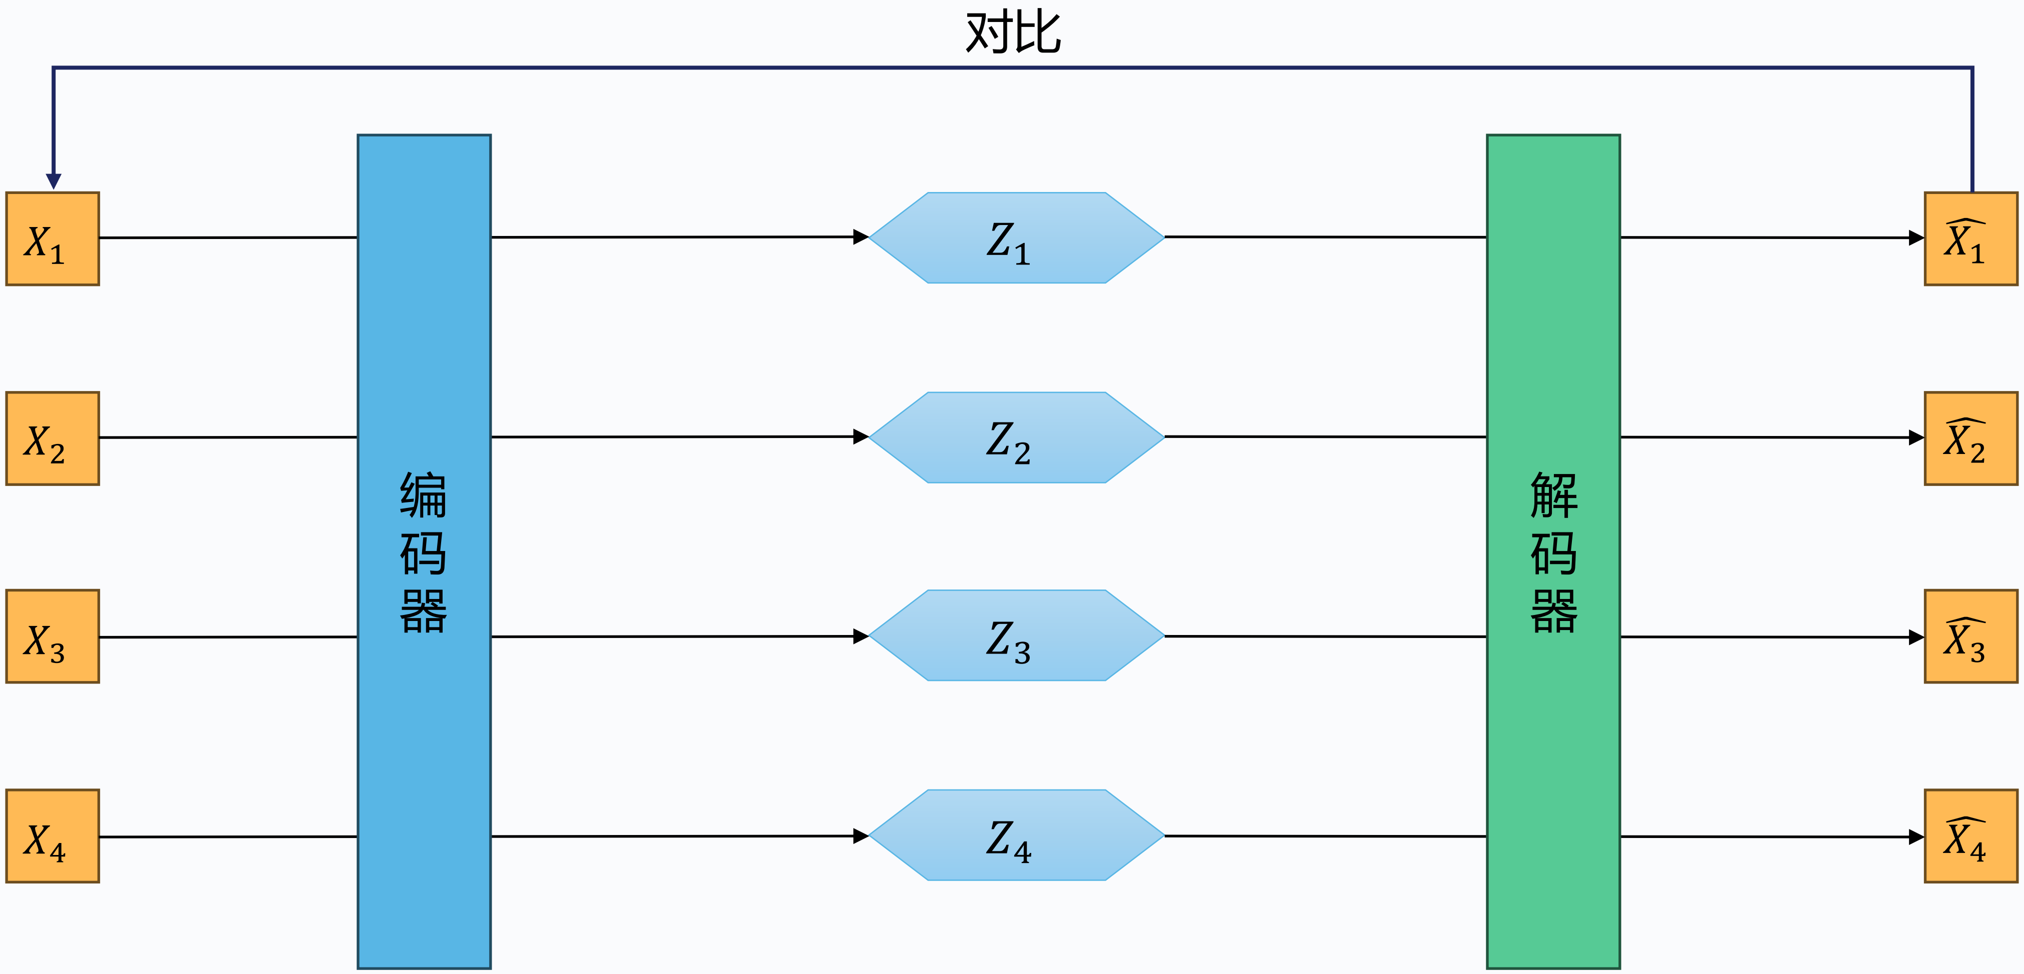
对比
X_1
X_2
X_3
X_4
编码器
Z_1
Z_2
Z_3
Z_4
解码器
$\widehat{X}_1$
$\widehat{X}_2$
$\widehat{X}_3$
$\widehat{X}_4$

加点噪声

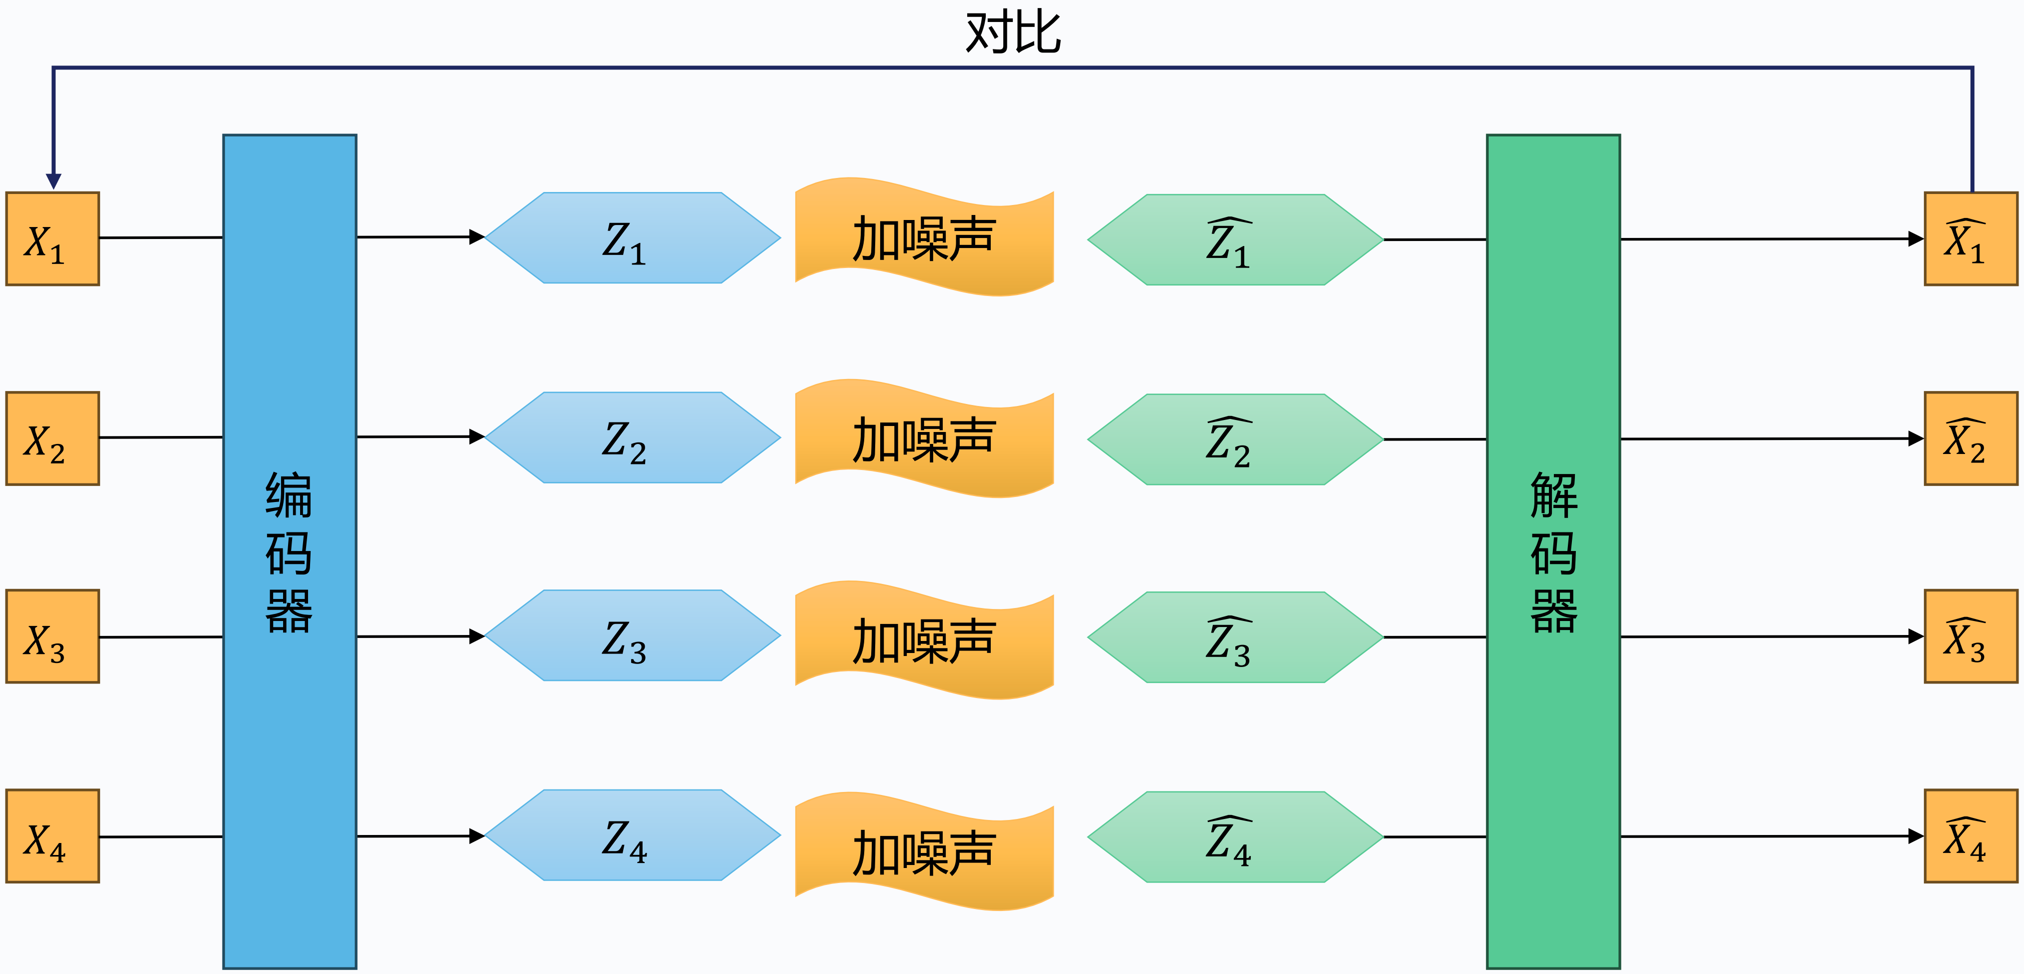

对比
X_1
X_2
X_3
X_4
编码器
Z_1
Z_2
Z_3
Z_4
加噪声
加噪声
加噪声
加噪声
$\widehat{Z}_1$
$\widehat{Z}_2$
$\widehat{Z}_3$
$\widehat{Z}_4$
解码器
$\widehat{X}_1$
$\widehat{X}_2$
$\widehat{X}_3$
$\widehat{X}_4$

加点噪声（等价的形式）

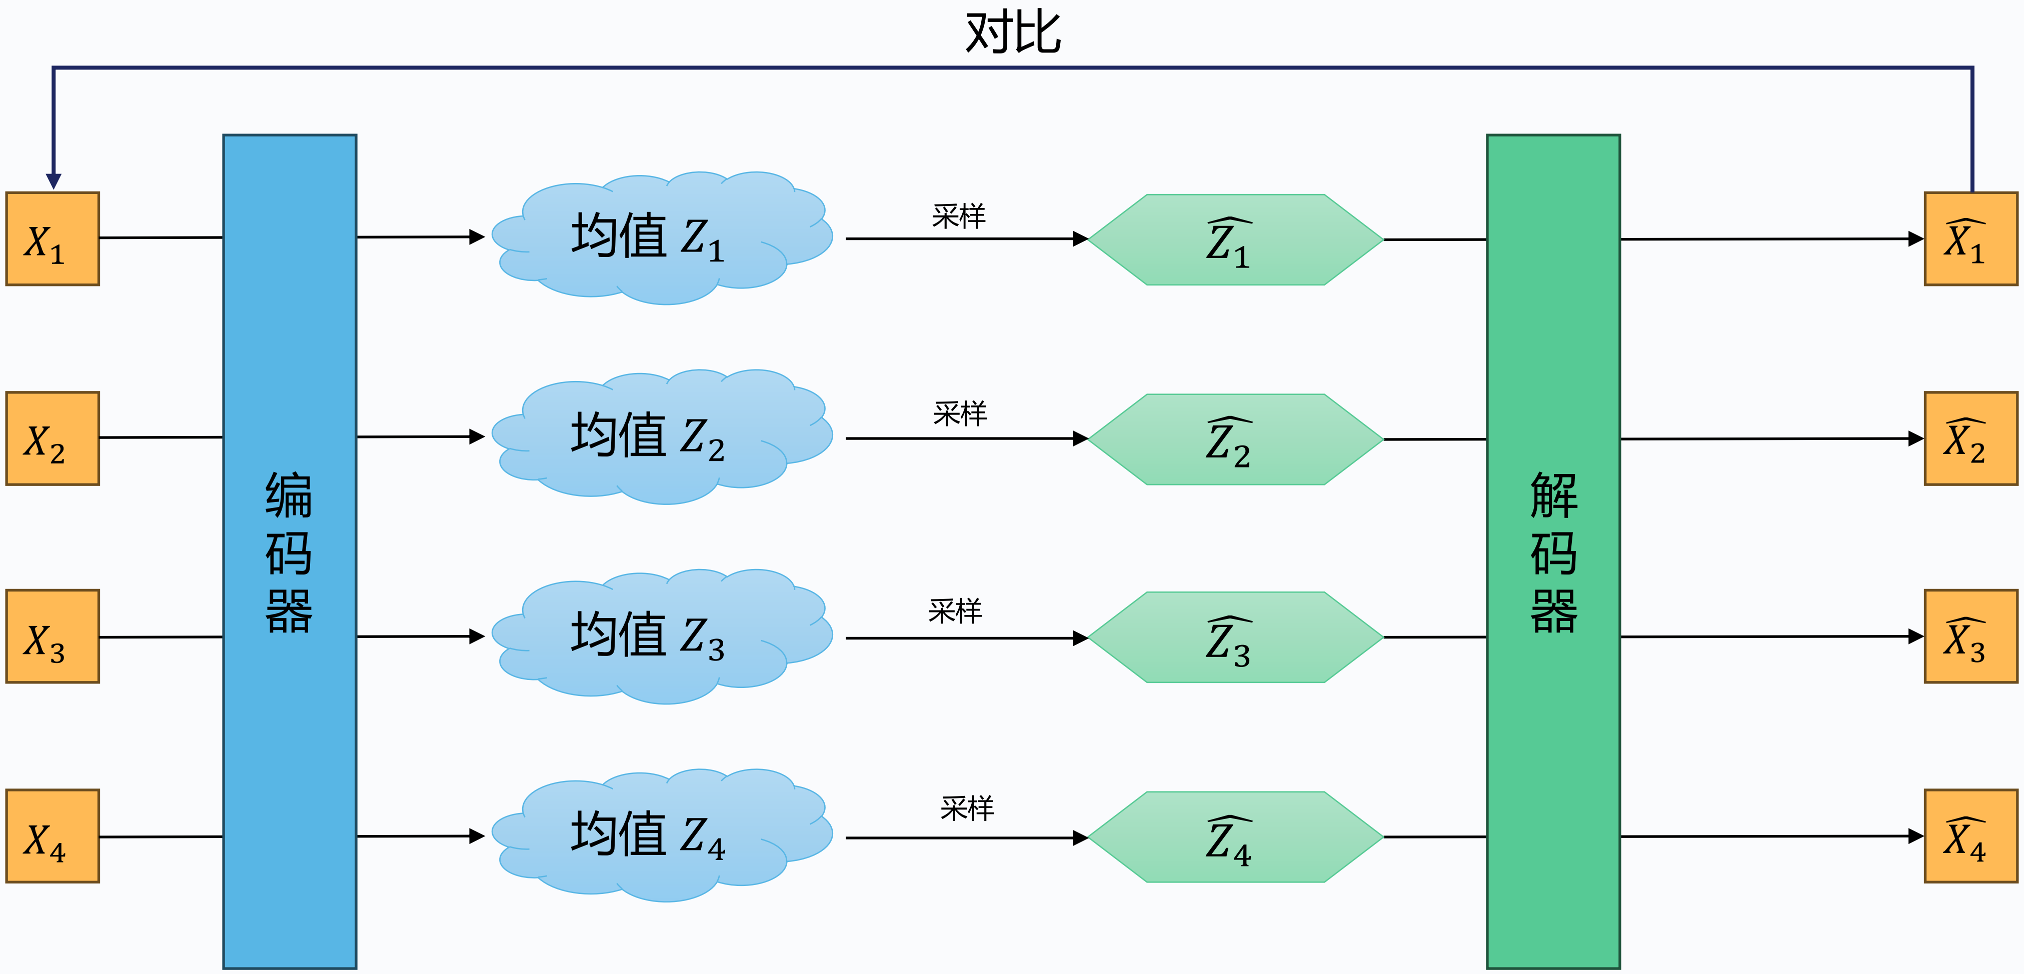

对比
X_1
X_2
X_3
X_4
编码器
均值 Z_1
均值 Z_2
均值 Z_3
均值 Z_4
采样
采样
采样
采样
$\widehat{Z}_1$
$\widehat{Z}_2$
$\widehat{Z}_3$
$\widehat{Z}_4$
解码器
$\widehat{X}_1$
$\widehat{X}_2$
$\widehat{X}_3$
$\widehat{X}_4$

变分自编码器的实现

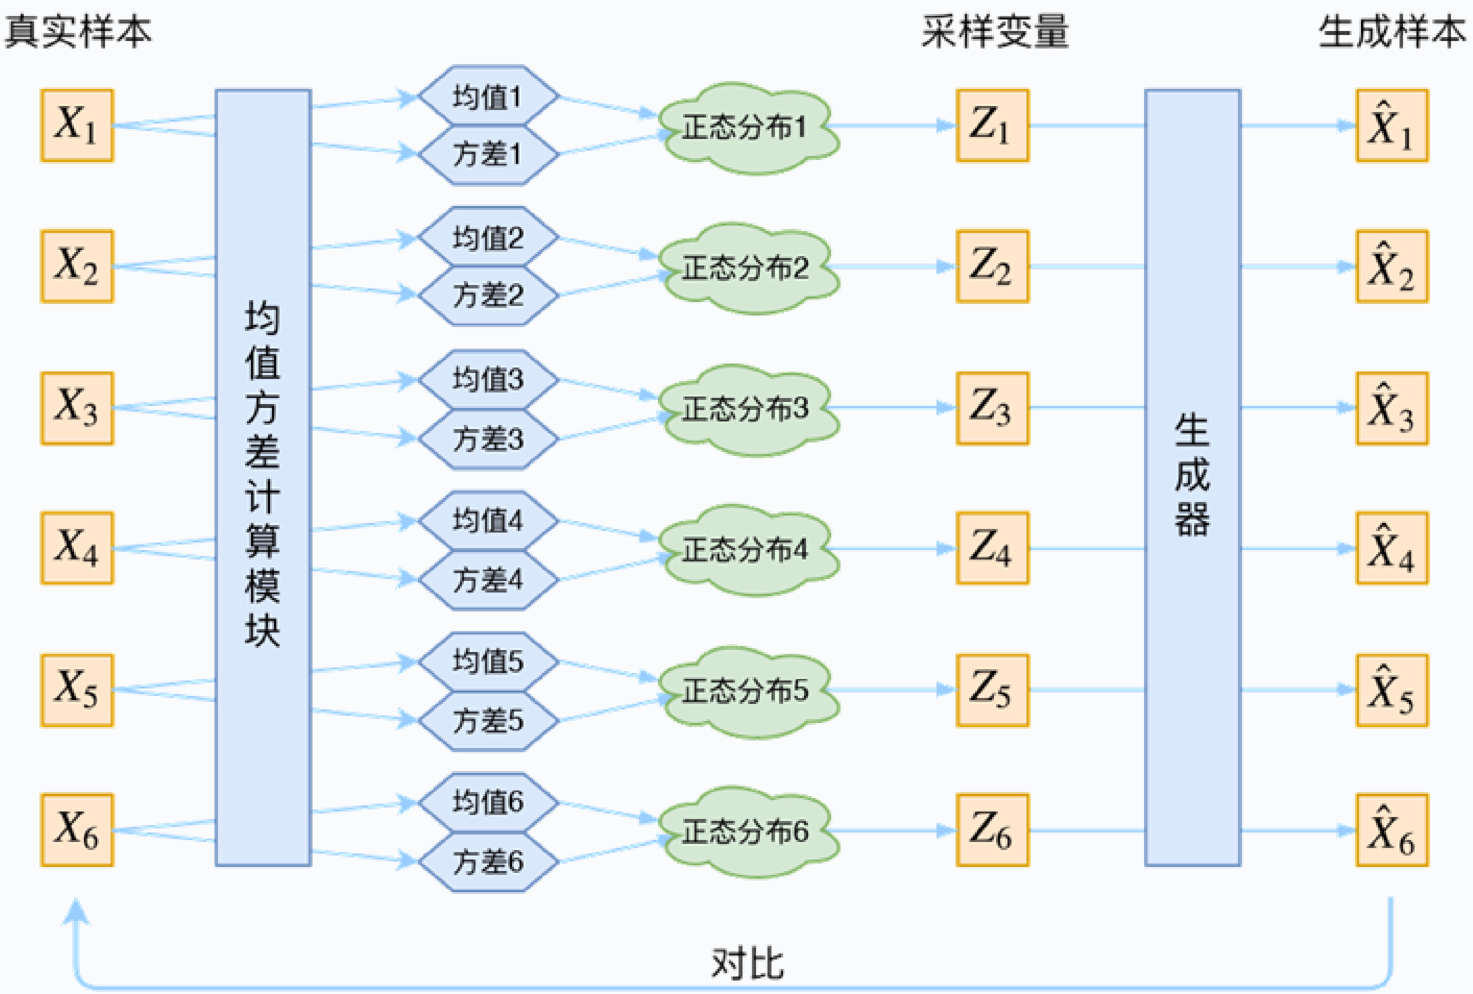

真实样本
采样变量
生成样本
X_1
X_2
X_3
X_4
X_5
X_6
均值方差计算模块
均值1
方差1
均值2
方差2
均值3
方差3
均值4
方差4
均值5
方差5
均值6
方差6
正态分布1
正态分布2
正态分布3
正态分布4
正态分布5
正态分布6
Z_1
Z_2
Z_3
Z_4
Z_5
Z_6
生成器
$\hat{X}_1$
$\hat{X}_2$
$\hat{X}_3$
$\hat{X}_4$
$\hat{X}_5$
$\hat{X}_6$
对比

正态分布有要求吗

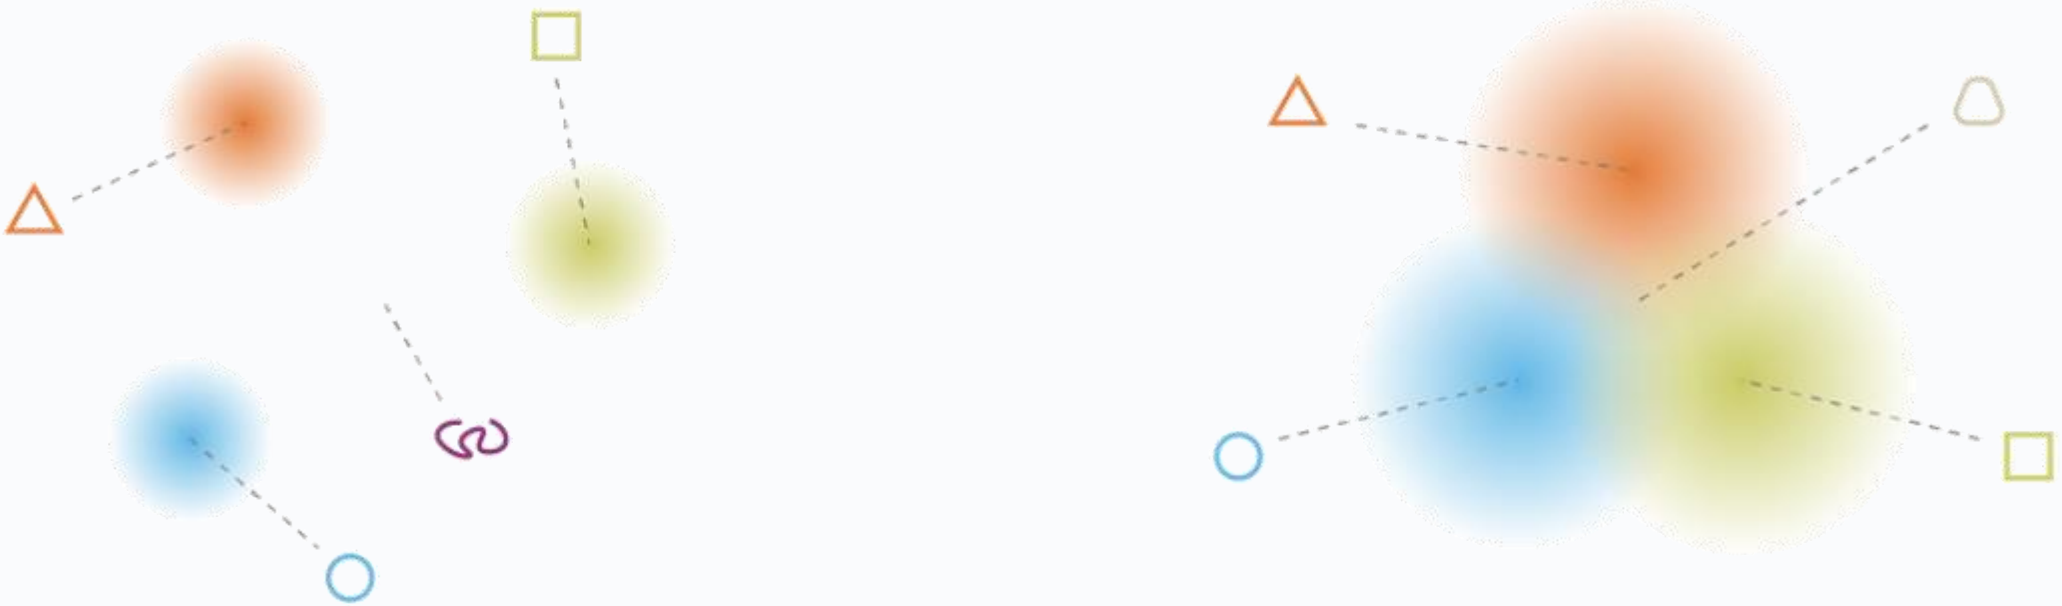

每一个正态分布都要向标准正态分布看齐

变分自编码器

损失函数

- 第一部分：重建损失
- 第二部分：正则化项

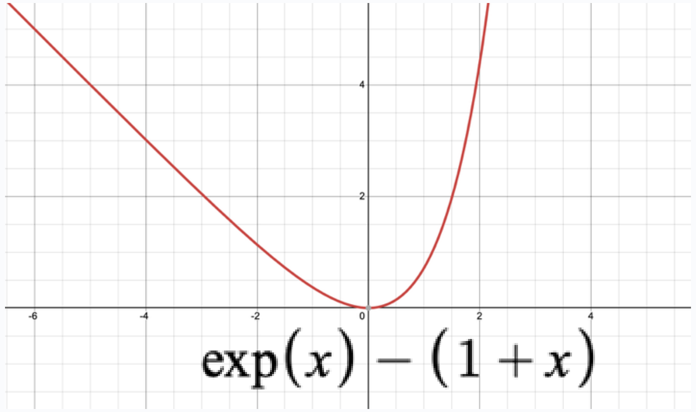

$$\sum_i \left(\boxed{\exp(\tilde{\sigma}_i) - (1 + \tilde{\sigma}_i)} + \boxed{\mu_i^2}\right)$$

$\tilde{\sigma}_i = \log \sigma^2$应在0附近；
隐编码的分布不要退化为单点分布

隐编码不要太分散（应在0附近）

正则化项为$\mathrm{KL}(N(\mu_i, \sigma_i^2)||N(0,1))$.