

Stable Diffusion

从扩散模型到文本生成图像

核心问题

模型如何从随机噪声逐步生成一张图像？

实验变量

prompt · seed · steps · guidance · negative prompt · LoRA

实验文件

wget -O stable_diffusion_lab.zip <https://icloud.bfsu.edu.cn/seafhttp/f/57047b2aaf2c4579a932/?op=view>
unzip stable_diffusion_lab.zip

Prompt

**“a small red robot
in a rainy city street”**



Latent denoising

UNet + Scheduler



Image

VAE Decoder output

这节课要回答的四个问题

1 Diffusion 在做什么？

从随机噪声逐步去噪，形成图像。

2 Stable Diffusion 改了什么？

把主要去噪过程放到 latent space，并加入文本条件。

3 推理时发生了什么？

Text Encoder、UNet、Scheduler、VAE 共同完成生成链路。

4 实验变量控制哪里？

prompt、seed、steps、guidance、negative prompt、LoRA 对应不同环节。

后续实验不是独立调参，而是在改变同一条 **Stable Diffusion** 推理链中的不同环节。

从噪声中逐步成像

扩散模型不是一步生成图像，而是把随机噪声逐步改造成结构清晰的样本。

“a small red robot in a rainy city street”



- 初始状态接近随机噪声，几乎看不出具体物体。
- 去噪过程先形成整体布局，再逐步稳定主体和场景。
- 后期更新主要补充边缘、纹理、颜色和局部细节。

DDPM: 多步去噪的生成链

DDPM 将生成过程表示为从 $\mathbf{x}_T$ 到 $\mathbf{x}_0$ 的反向链：每一步只做一次小更新。




Figure 2: The directed graphical model considered in this work.

- $\mathbf{x}_T$ 接近随机噪声， $\mathbf{x}_0$ 是最终样本。
- 反向链表达“从噪声逐步恢复图像”的思想。
- Stable Diffusion 仍保留多步去噪这一核心机制。

来源：Ho et al., Denoising Diffusion Probabilistic Models, Fig. 2

为什么模型会去噪：训练与推理的关系

训练阶段学习预测噪声；推理阶段反复使用这个能力。

训练阶段



训练时，先把真实图像加到某个噪声等级 t ，模型学习从 x_t 中预测被加入的噪声 ϵ 。

推理阶段



推理时，模型从随机latent z_T 开始，在latent space中逐步去噪得到 z_0 ，最后由VAE Decoder解码为图像。

模型的去噪能力，在训练中学会，在推理中被多次调用。

关键设计：在 **latent space** 中去噪

高分辨率 RGB 图像很大，直接在像素空间多步去噪成本高。Stable Diffusion 将主要去噪过程放到更小的 **latent** 表示中。



VAE Encoder

把图像压缩成 **latent** 表示，降低扩散过程的计算成本。


VAE Decoder

把最终 **latent z_0** 解码成 RGB 图像。

notebook 中把中间 **latent** 解码成图，只是为了观察；正常推理通常只在最后解码。

Stable Diffusion 推理流程：从输入到图像

文本条件和随机 latent 共同进入去噪循环；最终 latent 再由 VAE Decoder 解码为图像。



核心：每一步都在 latent space 中更新 z_t ；只有最后的 z_0 会通过 VAE Decoder 解码成可见图像。

Prompt 如何进入模型：从文字到文本特征


Prompt 不直接生成图像，而是先被编码成一组 text embeddings，作为后续去噪过程的条件输入。



Prompt 的直接输出不是图像，而是文本条件 **c_text**；真正的图像生成发生在后续去噪循环中。

Text prompt 如何引导去噪: cross-attention

c_text 不会单独生成图像; 它会在 UNet 的去噪层中作为条件被反复读取。



Guidance 与 Negative Prompt: 如何改变去噪方向

在每个去噪 step, UNet 会对同一个 latent 做两次噪声预测, 再用 guidance scale 组合两个方向。




$\epsilon_{\text{pos}} - \epsilon_{\text{neg}}$ 是“靠近正向 prompt、远离负向条件”的方向; s 越大, 这个方向被放大得越强。

Negative prompt 不是生成后删除内容, 而是在每一步去噪时改变负向参考方向。

因此 guidance 和 negative prompt 都是在去噪循环内部改变噪声预测方向, 而不是对最终图像做后处理。

Seed: 决定随机 latent 起点

Seed 不是语义指令，它只控制推理开始时的随机噪声。




固定 **seed** 便于复现实验；更换 **seed** 可以搜索不同构图、姿态和细节。

Scheduler 与 Steps: 去噪路径怎么走

训练可以定义很多噪声等级；推理时 scheduler 只选其中一部分时间点，并用 UNet 的噪声预测更新 latent。

训练噪声等级 $T = 1000$ 时，可以理解为从纯噪声到干净图像之间有 1000 个噪声位置。



推理采样路径



例如 $\text{steps} = 50$ 时，scheduler 从 1000 个训练噪声等级中选出 50 个时间点；每一步可以近似理解为跨过约 20 个训练时间步。

一次采样更新



这里的 t' 是下一个采样时间点，不一定等于 $t - 1$ ；DDIM 等采样器可以用较少步数完成整条去噪路径。

Steps 控制采样步数

步数越多，路径越细，通常更慢；步数太少，跳得更大，质量可能下降。

Scheduler 控制更新规则

选择时间点，并根据 UNet 预测的噪声把 z_t 更新到下一个 latent。

LoRA: 低成本改变模型生成倾向

LoRA 不改变 prompt 的文本含义，而是在模型权重上加入一个很小的低秩更新，使 UNet 更偏向某种风格或概念。



核心公式

$$W = W_0 + \alpha \cdot B A$$

α 对应 LoRA weight

为什么成本低？


- W_0 冻结，只训练很小的矩阵 A 和 B 。
- LoRA 文件只保存 ΔW ，因此体积远小于完整模型。

在 Stable Diffusion 中影响哪里？

- 主要改变 UNet 中部分线性层 / attention 层的行为。
- prompt 仍然决定内容，LoRA 改变模型对风格或概念的偏好。

实验中比较 Prompt-only 与 LoRA + prompt: 前者只改文本条件，后者还改变 UNet 的生成倾向。

把模块放回论文结构图



阅读重点

1. latent space
2. Denoising UNet
3. conditioning input

对应关系

绿色区域是 latent space; 右侧 conditioning 表示文本等条件参与生成。

来源: Rombach et al., High-Resolution Image Synthesis with Latent Diffusion Models, Fig. 3

Prompt 实验：从文字变化到图像变化

这三组实验都在改变文本条件，但改变的层级不同。

从简单到具体

a robot
→ small red robot
→ rainy city street
→ wet road / neon signs /
reflections

固定主体，改变场景

rainy city
snowy forest
desert
under the sea

固定主体和场景，改变风格

realistic photo
pencil sketch
low-poly 3D
watercolor

观察重点：哪些词带来了可见变化；不要一次改变太多词。

Seed 与 Steps 实验

一个控制随机起点，一个控制去噪路径长度。

Seed 实验

固定 prompt，比较 seed = 3 / 17 / 42 / 100

观察构图、主体位置、背景和细节的变化。

Steps 实验

固定 prompt 和 seed，比较 steps = 5 / 10 / 20 / 40

观察速度、结构稳定性和细节质量。

- seed 不是语义控制，它只决定随机 latent 起点。
- steps 不是“越大越好”，过多 steps 会增加时间，提升可能递减。

Guidance 与 Negative Prompt 实验

这两个参数都作用在每一步的文本引导方向上。

Guidance Scale

比较不同 s 值：文本条件越强，图像可能越贴近 **prompt**，但过高可能不自然。

Negative Prompt

改变 ϵ_{neg} 的方向：降低某些特征出现概率，但不是精确删除。

$$\epsilon = \epsilon_{neg} + s \cdot (\epsilon_{pos} - \epsilon_{neg})$$

观察目标是“倾向是否变化”，不是要求每个词都被严格执行。

LoRA 实验：Prompt-only 与 LoRA + Prompt

LoRA 通常和 prompt 一起工作，而不是单独作为“风格开关”。

Base

无 watercolor prompt
无 LoRA

Prompt-only

只用文本写出
watercolor style

LoRA + Prompt

加载 LoRA 后
再用 prompt 指定方向

LoRA weight

调节影响强度
过高可能异常

- 当前实验使用风景 prompt，更容易观察 watercolor 的纸张纹理和色彩晕染。
- LoRA 效果依赖权重、触发词、基础模型和 prompt。

实验变量应该放在流程中的哪个位置？

notebook 中每个变量都对应推理链中的一个环节。

Prompt	Text Encoder / c_{text}	改变文本条件
Seed	Random latent z_T	改变随机起点
Steps	Scheduler timesteps	改变去噪路径长度
Guidance	CFG strength	放大文本引导方向
Negative prompt	ϵ_{neg}	降低某些生成倾向
LoRA	UNet 权重倾向	改变模型风格/概念偏向

从这里开始进入 **notebook**: 每个实验只改变一个变量，观察图像如何变化。

小型创作流程：控制变量地调图

notebook 的最后几节把前面的变量组合成一次实际创作流程。



- 固定一个变量，再调整另一个变量，结果更容易解释。
- 保存 prompt、seed、steps、guidance 和是否使用 LoRA，便于复现。

课堂使用边界

生成式模型需要负责任地使用。

适合课堂展示

动物、风景、建筑、机器人、食物、科幻场景等。

避免生成

真实同学、老师、名人或公众人物；暴力、色情、仇恨、欺骗性或其他不适合课堂展示的内容。

不要把生成图像当作真实照片传播。本节课关注技术理解、变量控制和生成模型实验。

用一条推理链理解所有实验

prompt、seed、steps、guidance、negative prompt 和 LoRA 都能回到同一条流程解释。



- Stable Diffusion 从随机 latent 中逐步生成新图像，不是检索旧图。
- Latent diffusion 把主要去噪过程放到更小的 latent space 中。
- 实验的核心是控制变量，观察生成倾向和参数影响。

调参不是盲试，而是在改变推理链中的具体环节。