

第16讲 世界模型



神经网络与深度学习 2026

信息科学技术学院 吴瀚霖

hlwu@bfsu.edu.cn

世界模型

游戏、自动驾驶、视频生成、VR/AR



Sora

<https://openai.com/zh-Hans-CN/index/sora/>

2024.3




Genie: 可交互的视频生成

<https://deepmind.google/models/genie/>
2025.8



World Labs



<https://www.worldlabs.ai>

<https://marble.worldlabs.ai/world/8cd1cbc5-4cb2-4a94-ae24-9710c334ed73>

HY-World 2.0: 3D生成

 混元3D · 世界模型 2.0

DreamerV3: AI玩游戏



V-JEPA



理解世界



预测世界


Cosmos: 面向物理世界



Input Video



Output Video



什么是世界模型


人类如何预判下一秒会发生什么？

想象

预演



积木倒下



根据支撑关系和重力，预测下方失去支撑后，上方积木**会倒下**。



抽屉拉开



根据滑轨位置和空间结构，预测抽屉会沿轨道**向外拉出**。




皮球反弹



根据碰撞和弹性规律，预测皮球落地后会**向上反弹**。

心智模型 (Mental Model, 1943)



英国心理学家 Kenneth Craik

人在对现实世界做出反应前，会在大脑中构建一个小规模的内部模型，用来模拟可能发生的状态



理解世界



预测结果



指导行动

AI也需要这样一个小世界

智能体能做出优秀的决策，需要行动前在世界中先看到未来。

世界模型：能够预测环境在动作的影响下如何变化的神经网络。

World Models

<https://arxiv.org/pdf/1803.10122>

World Models

David Ha¹ Jürgen Schmidhuber^{2,3}

Abstract

We explore building generative neural network models of popular reinforcement learning environments. Our *world model* can be trained quickly in an unsupervised manner to learn a compressed spatial and temporal representation of the environment. By using features extracted from the world model as inputs to an agent, we can train a very compact and simple policy that can solve the required task. We can even train our agent entirely inside of its own hallucinated dream generated by its world model, and transfer this policy back into the actual environment.

An interactive version of this paper is available at
<https://worldmodels.github.io>




Figure 1. A World Model, from Scott McCloud's *Understanding Comics*. (McCloud, 1993; E, 2012)

current motor actions (Keller et al., 2012; Leinweber et al.,

[cs.LG] 9 May 2018

World Models

World Models

=

视觉模块 (V)

+

记忆模块 (M)

+

控制模块 (C)

观察世界

预测世界

做出行动

[cs.LG] 9 May 2018

World Models

David Ha¹ Jürgen Schmidhuber^{2,3}

Abstract

We explore building generative neural network models of popular reinforcement learning environments. Our *world model* can be trained quickly in an unsupervised manner to learn a compressed spatial and temporal representation of the environment. By using features extracted from the world model as inputs to an agent, we can train a very compact and simple policy that can solve the required task. We can even train our agent entirely inside of its own hallucinated dream generated by its world model, and transfer this policy back into the actual environment.

An interactive version of this paper is available at <https://worldmodels.github.io>




Figure 1. A World Model, from Scott McCloud's *Understanding Comics*. (McCloud, 1993; E, 2012)

current motor actions (Keller et al., 2012; Leinweber et al., 2012)

World Models

视觉模块 (V)



World Models

视觉模块 (V)



1
0
0
1
...
1

World Models

记忆模块 (M)

“物理引擎”


轻挡回球



大力扣杀



下旋球




World Models



提取特征

模拟方案

梦中试错->做出决策



World Models

<https://arxiv.org/pdf/1803.10122>

At each time step, our agent receives an **observation** from the environment.


World Model

The **Vision Model (V)** encodes the high-dimensional observation into a low-dimensional latent vector.

The **Memory RNN (M)** integrates the historical codes to create a representation that can predict future states.

A small **Controller (C)** uses the representations from both **V** and **M** to select good actions.

The agent performs **actions** that go back and affect the environment.



World Models




世界模型的三个特质

1. 表示世界 Representation




把环境中的对象、关系与状态
组织成**内部表征**。

2. 预测未来 Prediction



根据当前状态，推断**接下来可能发生什么**。

3. 规划和行动 Planning & Control



利用内部模拟评估方案，
并**选择合适的行动**。

目标：让AI像人类一样，会观察、会推理、会行动

世界模型 v.s. LLM

预测目标不同



下一个Token

水杯会从桌子上掉落吗?

会

生成语言上看起来合理的序列

世界模型 v.s. LLM

预测目标不同



下一个Token



下一秒世界的样子

下一帧

下一个状态

下一个行为

理解物理规律、空间关系、动态变化

世界模型 v.s. LLM

训练数据不同

LLM

文本

图像

视频

以静态内容为主

世界模型

视频

传感器反馈


机器人的动作结果

环境变化等

以动态内容为主，强调时序性

世界模型 v.s. LLM

理解世界的方式



LLM

The diagram is split into two columns by a vertical yellow line. The left column represents LLM, with a dark blue circle at the top. Below it are two rounded rectangular boxes: the first contains the word '间接的' (Indirect), and the second contains '借助于学习文本中的统计规律' (Assisting in learning statistical patterns from text). The right column represents the World Model, with an orange circle at the top. Below it are two rounded rectangular boxes: the first contains the word '直接的' (Direct), and the second contains '通过交互、推演理解世界的物理规律' (Understanding the physical laws of the world through interaction and deduction).

间接的

借助于学习文本中的
统计规律

世界
模型


直接的

通过交互、推演理解
世界的物理规律

世界模型 v.s. LLM



世界模型 v.s. LLM



① AI 是最大集合, 涵盖所有人工智能方向 ② LLM 与 World Model 均是 AI 的子集 (真子集) ③ $LLM \cap World Model \neq \emptyset$ (两者有交集, 但各有侧重)

为什么世界模型突然受到人们的关注

LLM是通向AGI的死路



TECH

Meta chief AI scientist Yann LeCun is leaving to create his own startup
Meta 首席人工智能科学家 Yann LeCun 即将离职，创立自己的初创公司。

PUBLISHED WED, NOV 19 2025 4:31 PM EST | UPDATED WED, NOV 19 2025 8:58 PM EST

Jonathan Vanian
@JONATHAN-VANIAN-B704432/

为什么世界模型突然受到人们的关注

Moravec悖论

对人类而言易如反掌的感官运动技能（如行走，感知）对AI来说极其困难；

对人类来说很难的逻辑推理（如数学、棋类）对AI来说却轻而易举。


为什么世界模型突然受到人们的关注

LLM的Scaling Law还能持续多久？

继续做**大**模型，不会带来质的突破；
(受到算力、能源、数据的约束，性价比不高)

现实世界远比语言世界更加**混乱、连续、充满不确定性因素**

如何理解世界模型的研究



路线1：视频生成

如何能够“画”出来世界，就必须先理解世界

- 物体会如何在物理定律下移动
- 光线如何变化
- 代表产品
 - 播放世界：Sora、Seedance、Kling
 - 探索世界：Genie（实时、长时间一致性、记忆）



In addition to being able to generate a video solely from text instructions, the model is able to take an existing still image and generate a video from it, animating the image's contents with accuracy and attention to small detail. The model can also take an existing video and extend it or fill in missing frames. [Learn more in our technical report.](#)


Sora serves as a foundation for models that can understand and simulate the real world, a capability we believe will be an important milestone for achieving AGI.

Genie


<https://arxiv.org/pdf/2402.15391>

Prompt

Text-to-image



Hand-drawn sketch




Real-world photo



Genie

Play:  {A, B, X, Y}



Genie

<https://arxiv.org/pdf/2402.15391>




Figure 3 | **Genie model training:** Genie takes in T frames of video as input, tokenizes them into discrete tokens z via the video tokenizer, and infers the latent actions $\tilde{a}$ between each frame with the latent action model. Both are then passed to the dynamics model to generate predictions for the next frames in an iterative manner.





Figure 8 | **Genie Inference:** the prompt frame is tokenized, combined with the latent action taken by the user, and passed to the dynamics model for iterative generation. The predicted frame tokens are then decoded back to image space via the tokenizer's decoder.

Genie



<https://labs.google/projectgenie>

路线1：视频生成

02 表现形式

世界生成

视频生成

- Sora
- Genie

优点

- 结果看得见
- 数据容易获取
- 容易Scale Up

缺点

- 结果是“显示”
- 对于世界的理解是“隐式”，无法使用（指导机器人行动）
- 计算复杂度太高

01 思想与范式

表示世界、预测未来、规划和行动

路线1：视频生成

★ 共同点：都是 scale-driven 的模型



大数据



大模型



大算力



性能随规模提升



大语言模型 (LLM)

我 今天 想 吃 火锅 ? → 吧



Transformer / LLM



核心任务：预测下一个 token



输入是序列



自回归建模



在大规模数据上训练



视频生成模型



t



t+1



t+2



t+3



t+4



t+5



Video Model / Transformer / Diffusion



核心任务：预测下一个帧



输入是时序序列



建模时间依赖



在大规模视频数据上训练

路线1：视频生成



表象

- ✓ 造型光影逼真
- ✓ 运动流畅

结构

- ? 车的长、宽、高
- ? 内部结构是什么样的?

仅仅学会了像素组合的概率分布，而不会真的构建一个三维几何模型

路线2：3D生成


不是把世界画出来，而是建模出来

3D 网格文件

- 更关注世界的结构
- 物体的位置
- 空间几何关系
- 物体之间如何相互影响



真正的世界是3D，AI必须理解空间，才能理解世界

- 机器人的行动需要理解空间
- 自动驾驶需要




路线2：3D生成

高斯泼溅




路线2：3D生成



没有实现预测未来，让智能体在生成的世界里行动

世界模型是一个训练场



用世界模型训练更智能的AI

现实世界的训练太昂贵

- 采集数据成本高
- 不可能提供给AI**伤害人类**的负样本
- 自动驾驶中的长尾样本

游戏本身就是虚拟世界

- 下棋：AlphaGo, 2017
- Dota 2：OpenAI Five, 2018
- 星际争霸：Deepmind AlphaStar, 2018



基于强化学习训练智能体

SIMA2: 基于虚拟世界训练AI行动



<https://deepmind.google/blog/sima-2-an-agent-that-plays-reasons-and-learns-with-you-in-virtual-3d-worlds/>

SIMA2：基于虚拟世界训练AI行动

SIMA: Scalable Instructable Multiworld Agent

- 本质上是一个VLA模型
- 使用了Genie3生成的虚拟世界进行了训练

能力突破

- 集成了Gemini，具有自主思考与复杂任务处理
- 具有强大的泛化能力，能在从未见过的游戏中Work
- 具有迁移到真实世界的潜力

终极目标：让智能体在任何3D世界中行动、探索、推理

虚拟世界一定要“被看见”吗？

在抽象世界中训练

□ JEPA

03

目的

智能体训练

在虚拟世界中训练

□ SIMA

02 表现形式

世界模型 ≠ 逼真的画面


大量算力用来“画细节”

高分辨率纹理、逼真像素、复杂外观



却未必理解世界结构

因果关系、物体交互、动力学规律、可预测的抽象表示



理解世界比画出来世界更重要

抽象是什么？

我们对世界的
不同层级抽象



原子



分子



蛋白质



细胞



生物



生态系统



社会


抽象 = 在合适层级上表示世界。

找到抽象表示，是预测的关键

直接预测
下一个位置：
困难。



从复杂到简洁：
选择合适的抽象




掌握规律 +
椭圆轨道：
少量参数
预测任意时刻。

JEPA

Joint Embedding Predictive Architecture

不预测图像、不生成视觉内容



把真实世界压缩为**潜在表示**，然后在潜空间中做预测

视频模型

下一帧球的位置

阴影与光照

材质的反射

JEPA


滚动方向

速度变化

是否有碰撞

只关心与任务
或者决策相关的
变化


JEPA



V-JEPA 2

<https://ai.meta.com/research/vjepa/>


预训练



V-JEPA 2

<https://ai.meta.com/research/vjepa/>

后训练



V-JEPA 2

<https://ai.meta.com/research/vjepa/>


零样本的机器人规划

在陌生环境中，与陌
生物体交互



直接学习世界的
抽象结构

□ JEPA



在虚拟世界中训练

□ SIMA

02 表现形式

JEPA

优点

- 不画世界，计算成本更低
- 只保留关键结构信息，更容易捕捉因果关系
- 贴合具身智能的需求



直接学习世界的 抽象结构

□ JEPA

03

目的

智能体训练

在虚拟

□ SIMA

02 表现形式

JEPA

优点


- 不画世界，计算成本更低
- 只保留关键结构信息，更容易捕捉因果关系
- 贴合具身智能的需求

挑战

- 不可见
- 自监督的目标不容易设计（什么才是结构？）
- 缺乏评估标准

直接学习世界的抽象结构

□ JEPA




Dreamer

1. 基本思路


Dreamer 并不只在真实环境中反复试错学习。它先学习一个世界模型，理解环境如何运作；然后在模型内部想象未来轨迹，利用这些想象的经验来学习如何更好地行动。

- ✓ 更高效的数据利用
- ✓ 更少的环境交互
- ✓ 可在模型中“想象”未来
- ✓ 更好的泛化能力

A. 传统强化学习



B. Dreamer (世界模型驱动)



核心：先学会表示世界，再在模型内部 rollout 未来，用 imagined trajectories 训练策略。

2. Dreamer 的做法 (整体流程)

1 从环境收集数据

与环境交互，收集序列 $(o_t, a_t, r_t, o_{t+1}, done)$ 。

2 学习世界模型

从历史观测与动作中学习潜在状态表示，并预测未来状态与奖励。

3 在模型中想象 (Imagine)


从当前潜在状态出发，在隐空间 rollout，生成未来状态、奖励和终止信号。

4 在想象轨迹上学习策略

基于 imagined trajectories 训练 Actor-Critic，优化行为策略。

5 周期性更新，迭代优化

用新数据不断更新世界模型和策略，循环往复。



世界模型会改变什么？



编程好的动作

难以实现跨环境的迁移

让机器人有内部的世界模型



能够推断自己的动作会产生什么后果

世界模型会改变什么？



极端天气

突发事故

不规范的行人

世界模型的潜在风险

语言模型的幻觉只是编造事实

世界模型的幻觉出现在“世界结构”里

- 高估动作的可行性
- 低估碰撞后果
- 构建了错误因果关系



直接影响智能体的决策和行动

世界模型的潜在风险

权利集中

只有少数机构掌握世界模型

可以对市场、社会行为、群体反应做出预测

信息垄断、社会操纵